

UNIVERSITAS DIPONEGORO

STUDI KOMPARATIF ARSITEKTUR BACKBONE MODEL CNN PADA YOLOV5 UNTUK EFISIENSI DETEKSI OBJEK DALAM IDENTIFIKASI JENIS TANAMAN

TUGAS AKHIR

Diajukan sebagai salah satu syarat untuk memperoleh gelar
Sarjana Teknik

ZEKA EMO
21120122130075

FAKULTAS TEKNIK
DEPARTEMEN TEKNIK KOMPUTER
SEMARANG
2026

HALAMAN PENGESAHAN

Tugas Akhir

STUDI KOMPARATIF ARSITEKTUR BACKBONE MODEL CNN PADA YOLOV5 UNTUK EFISIENSI OBJECT DETECTION DALAM IDENTIFIKASI JENIS TANAMAN

Tugas Akhir ini daijukan oleh:

Zeka Emo

21120122130075

Kepada

Departemen Teknik Komputer

Universitas Diponegoro

Telah disetujui Oleh

Pembimbing I	Pembimbing II
Bellia Dwi Cahya Putri, S.T., M.T.	Yudi Eko Windarto, S.T., M.Kom
H.7.199210142022102001	H.7.198906042018071001

HALAMAN PENGESAHAN

Tugas Akhir ini diajukan oleh :

Nama	:	Zeka Emo
NIM	:	21120122130075
Departemen	:	Teknik Komputer
Judul Tugas Akhir	:	Studi Komparatif Arsitektur Backbone Model CNN pada YOLOv5 untuk Efisiensi Deteksi Objek dalam Identifikasi Jenis Tanaman

Telah berhasil dipertahankan di hadapan Tim Penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh gelar Sarjana Teknik pada Departemen Teknik Komputer, Fakultas Teknik, Universitas Diponegoro.

TIM PENGUJI

Pembimbing I	:	Bellia Dwi Cahya Putri, S.T., M.T.	( )
Pembimbing II	:	Yudi Eko Windarto, S.T., M.Kom.	( )
Ketua Penguji	:	Prof. Dr. Ir. R. Rizal Isnanto, S.T., M.M., M.T., IPU, ASEAN Eng.	( )
Anggota Pengguji	:	Kuntoro Adi Nugroho, S.T., M.Eng.,Ph.D.	( )

Semarang, 23 September 2026

Ketua Departemen Teknik Komputer

Dr. Maman Somantri, S.T., M.T.

NIP. 197406271999031002

HALAMAN PERNYATAAN ORISINALITAS

Tugas Akhir ini adalah hasil karya saya sendiri dan semua sumber baik yang dikutip maupun yang dirujuk telah saya nyatakan dengan benar.

Nama	:	Zeka Emo
NIM	:	21120122130075
Tanda Tangan	:	
Tanggal	:	Semarang, 14 Agustus 2026

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai sivitas akademika Universitas Diponegoro, saya yang bertanda tangan di bawah ini:

Nama : Zeka Emo
NIM : 21120122130075
Departemen : Teknik Komputer
Fakultas : Teknik
Jenis Karya : Tugas Akhir

Demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Diponegoro *Hak Bebas Royalti Non-eksklusif* (*Non-exclusive Royalti Free Right*) atas karya ilmiah saya berjudul:

Studi Komparatif Arsitektur Backbone Model CNN Pada YoloV5 Untuk Efisiensi Deteksi Objek Dalam Identifikasi Jenis Tanaman beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti/Non-eksklusif ini Universitas Diponegoro berhak menyimpan, mengalih media/formatkan, mengelola, dalam bentuk pangkalan data (*database*), merawat dan memublikasikan Tugas Akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Semarang
Pada Tanggal : 14 Agustus 2026

Yang menyatakan,



ZEKA EMO

KATA PENGANTAR

Puji syukur penulis panjatkan kehadirat Allah SWT atas segala limpahan rahmat, hidayah, dan karunia-Nya, sehingga penulis dapat menyelesaikan Tugas Akhir dengan judul "Studi Komparatif Arsitektur Backbone Model CNN Pada YoloV5 Untuk Efisiensi Object Detection Dalam Identifikasi Jenis Tanaman".

Penyusunan Tugas Akhir ini merupakan salah satu syarat wajib untuk menyelesaikan program studi dan memperoleh gelar Sarjana Teknik pada Departemen Teknik Komputer Universitas Diponegoro. Penelitian yang diangkat dalam Tugas Akhir ini berfokus pada analisis komparatif arsitektur *deep learning* untuk mengevaluasi *trade-off* antara akurasi dan efisiensi komputasi pada model deteksi objek.

Dalam proses penyusunan Tugas Akhir ini, penulis menyadari bahwa banyak pihak telah memberikan bimbingan, dukungan, doa, dan semangat yang sangat berarti. Oleh karena itu, penulis ingin menyampaikan rasa terima kasih yang tulus dan penghargaan setinggi-tingginya kepada:

1. Orang tua penulis, Ibu dan Ayah serta Azka, yang telah memberikan doa yang tiada putus, dukungan moril maupun materil, dan kasih sayang yang tak terhingga.
2. Bapak Dr. Maman Somantri S.T., M.T., selaku Ketua Departemen Teknik Komputer Universitas Diponegoro, atas segala fasilitas dan kemudahan administrasi yang telah diberikan.
3. Ibu Bellia Dwi Cahya Putri, S.T., M.T. selaku Dosen Pembimbing I dan Bapak Yudi Eko Windarto, S.T., M.Kom selaku Dosen Pembimbing II. Penulis mengucapkan terima kasih yang tak terhingga atas ketersediaan waktu, bimbingan, arahan, diskusi, dan masukan konstruktif selama proses penelitian hingga penyelesaian Tugas Akhir ini.
4. Tim Capstone, Annastasha dan Nalendra yang telah membantu dan berkontribusi secara aktif dalam pengembangan dan penulisan sistem yang diajukan.

5. Sahabat-sahabat penulis, "Perseghi", yaitu Asha, Praba, dan Cacak, atas segala semangat, tawa, dan dukungan dalam melalui suka duka selama masa perkuliahan.
6. Seluruh rekan-rekan angkatan 2022 dan semua pihak yang tidak dapat penulis sebutkan satu per satu, terima kasih atas kebersamaan dan bantuannya.

Penulis menyadari sepenuhnya bahwa Tugas Akhir ini masih jauh dari kata sempurna dan memiliki banyak kekurangan. Oleh karena itu, segala bentuk kritik dan saran yang membangun akan penulis terima dengan terbuka demi perbaikan di masa mendatang.

Semoga Tugas Akhir ini dapat memberikan manfaat, baik secara teoretis maupun praktis, bagi pembaca serta berkontribusi pada pengembangan ilmu pengetahuan. Akhir kata, penulis mengucapkan terima kasih.

Semarang, 14 Agustus 2026



ZEKA EMO

DAFTAR ISI

HALAMAN PENGESAHAN ii
HALAMAN PERNYATAAN ORISINALITAS iii
HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS iv
KATA PENGANTAR v
DAFTAR ISI vii
DAFTAR GAMBAR ix
DAFTAR TABEL x
ABSTRAK xi
ABSTRACT xii
BAB I PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Rumusan Masalah 3
1.3 Batasan Masalah 3
1.4 Tujuan Penelitian 4
1.5 Manfaat Penelitian 4
1.6 Metode Penelitian 5
1.7 Sistematika Penulisan 7
BAB II KAJIAN PUSTAKA 9
2.1 Penelitian Terdahulu 9
2.2 Landasan Teori 15
2.2.1 Object Detection 15
2.2.2 YOLOv5 15
2.2.3 ResNet152 17

2.2.4 EfficientNetB1 17
2.2.5 VGG16-BN 18
2.2.6 MobileNet-Large 19
2.2.7 Augmentasi Data 19
2.2.8 Roboflow 20
2.2.9 Metrik Evaluasi 20
BAB III METODE PENELITIAN 23
3.1 Merancang Alur Penelitian 23
3.2 Persiapan Data 24
3.3 Perancangan Arsitektur Model 26
3.4 Melatih Model 27
3.5 Analisis dan Evaluasi Hasil 29
BAB IV HASIL PENELITIAN DAN PEMBAHASAN 31
4.1 Hasil Penelitian 31
4.2 Pembahasan 33
4.2.1. Analisis Akurasi 33
4.2.2. Analisis Efisiensi Komputasi 34
4.2.3. Analisis Nilai Efisiensi 35
BAB V PENUTUP 38
5.1 Kesimpulan 38
5.2 Saran 39
DAFTAR PUSTAKA 41
BIODATA MAHASISWA 45
LAMPIRAN 46

DAFTAR GAMBAR

Gambar 2. 1 Arsitektur model YOLOv5..... 16

Gambar 3. 1 Diagram Alur Penelitian..... 24

Gambar 4. 1 Diagram *confusion matrix* pada hasil YOLOv5 + EfficientNet..... 32

DAFTAR TABEL

Tabel 2. 1 Ringkasan Studi Literatur Terdahulu Berdasarkan Identifikasi Tanaman Berbasis CNN dan Fitur Visual 13
Tabel 2. 2 Ringkasan Studi Literatur Terdahulu Berdasarkan Deteksi Objek Modern dan Model Hibrida 13
Tabel 2. 3 Ringkasan Studi Literatur Terdahulu Berdasarkan Efisiensi Komputasi dan Studi Komparatif *Backbone* 14
Tabel 3. 1 Distribusi Data Sebelum Augmentasi 25
Tabel 3. 2 Distribusi Data Setelah Augmentasi 26
Tabel 3. 3 Tabel perbandingan backbone CNN 27
Tabel 3. 4 Tabel Parameter pelatihan model 28
Tabel 4. 1 Tabel Hasil performa model 31

ABSTRAK

KHDTK Wanadipa Universitas Diponegoro memiliki keanekaragaman hayati yang tinggi (114 spesies), namun proses identifikasi tanaman di lapangan masih bergantung pada metode manual yang lambat dan ketersediaan pakar, sehingga membatasi akses edukasi bagi masyarakat. Meskipun deep learning (CNN) menawarkan solusi, sebagian besar penelitian hanya berfokus pada akurasi dan mengabaikan efisiensi komputasi yang krusial untuk aplikasi real-time. Penelitian ini bertujuan untuk menemukan arsitektur backbone optimal untuk model YOLOv5 yang memberikan keseimbangan (trade-off) terbaik antara akurasi dan efisiensi. Empat backbone (EfficientNetB1, ResNet152, VGG16-BN, MobileNet-Large) dibandingkan dengan baseline YOLOv5N untuk diimplementasikan dalam sistem informasi berbasis web.

Metodologi penelitian dimulai dengan pengumpulan dataset 13 spesies tanaman dari KHDTK, menghasilkan 631 gambar yang kemudian diaugmentasi menjadi 1.553 gambar. Setiap model (empat varian backbone kustom dan satu baseline) dilatih selama 300 epoch menggunakan hardware (NVIDIA A100) dan hyperparameter yang seragam untuk menjamin perbandingan yang adil. Evaluasi performa dilakukan dengan mengukur metrik akurasi (Precision, Recall, mAP@0.5, mAP@0.5:0.95) dan efisiensi komputasi (GFLOPs dan FPS), dengan fokus utama menemukan trade-off terbaik melalui perhitungan Efficiency Score (mAP/GFLOPs).

Hasil penelitian menunjukkan bahwa baseline, yaitu model YOLOv5N standar tanpa modifikasi backbone yang digunakan sebagai acuan pembanding utama, memiliki akurasi tertinggi (mAP@0.5: 0,980) namun dengan biaya komputasi yang relatif tinggi (24,1 GFLOPs). Di antara backbone kustom, EfficientNetB1 (mAP@0.5: 0,911) menjadi yang paling akurat dan secara bersamaan paling efisien secara komputasi (6,1 GFLOPs), mencapai Nilai Efisiensi tertinggi (14,93), 3,7 kali lebih baik daripada baseline (4,07). Pengukuran Frames Per Second (FPS) turut dilakukan dan menunjukkan EfficientNetB1 (47,33 FPS) sedikit lebih lambat dibandingkan baseline (80,18 FPS), namun korelasi negatif sedang hingga kuat antara GFLOPs dan FPS (ρ = -0,600) mengindikasikan selisih ini lebih disebabkan oleh keterbatasan optimasi implementasi dibandingkan kelemahan arsitektur. Disimpulkan bahwa EfficientNetB1 tetap merupakan backbone paling optimal berdasarkan keseimbangan akurasi dan efisiensi komputasi arsitektural, sehingga dipilih untuk implementasi akhir pada aplikasi web.

Kata kunci: *Object Detection; Identifikasi Jenis Tanaman; YOLOv5; Rekonstruksi Model*

ABSTRACT

The Wanadipa KHDTK at Diponegoro University possesses high biodiversity (114 species), yet plant identification relies on slow, manual, expert-dependent methods, limiting educational access for the public. While deep learning (CNN) offers a solution, most research focuses solely on accuracy, ignoring the computational efficiency crucial for real-time applications. This study aims to find the optimal backbone architecture for a YOLOv5 model that provides the best trade-off between accuracy and efficiency. Four backbones (EfficientNetB1, ResNet152, VGG16-BN, MobileNet-Large) were compared against a YOLOv5N baseline for implementation in a web-based information system.

The methodology began with collecting a dataset of 13 plant species from KHDTK, yielding 631 images, which were then augmented to 1,553 images. Each model (four custom backbone variants and one baseline) was trained for 300 epochs using uniform hardware (NVIDIA A100) and hyperparameters to ensure a fair comparison. Performance was evaluated using accuracy metrics (Precision, Recall, mAP@0.5, mAP@0.5:0.95) and computational efficiency (GFLOPs and FPS), focusing on the best trade-off via an "Efficiency Score" (mAP/GFLOPs).

The results showed that the baseline, namely the standard YOLOv5N model without any backbone modification used as the main point of comparison, achieved the highest accuracy (mAP@0.5: 0.980) but at a relatively high computational cost (24.1 GFLOPs). Among the custom backbones, EfficientNetB1 (mAP@0.5: 0.911) was the most accurate and simultaneously the most computationally efficient (6.1 GFLOPs), achieving the highest Efficiency Value (14.93), 3.7 times better than the baseline (4.07). Frames Per Second (FPS) measurements were also conducted and showed EfficientNetB1 (47.33 FPS) to be slightly slower than the baseline (80.18 FPS), although a moderate to strong negative correlation between GFLOPs and FPS (ρ = -0.600) indicates that this gap is more likely attributable to implementation optimization limitations rather than an architectural weakness. It was concluded that EfficientNetB1 remains the optimal backbone based on the balance of accuracy and architectural computational efficiency, and was therefore selected for the final web application deployment.

Keywords: *Object Detection; Plant Identification; YOLOv5; Model Reconstruction*

BAB I
PENDAHULUAN

1.1 Latar Belakang

Kawasan Hutan dengan Tujuan Khusus (KHDTK) Wanadipa merupakan aset milik Universitas Diponegoro yang berlokasi di wilayah Hutan Penggaron di Kabupaten Semarang. Fungsi utamanya adalah untuk mendukung pelaksanaan Tri Dharma Perguruan Tinggi, yang mencakup pendidikan, penelitian, dan pengabdian kepada masyarakat. Kawasan ini secara spesifik dimanfaatkan sebagai laboratorium atau kampus lapangan untuk berbagai kegiatan akademik dan riset bagi sivitas akademika. Selain itu, KHDTK Wanadipa juga berperan sebagai wahana penting untuk pengembangan ilmu pengetahuan kehutanan serta pelestarian sumber daya alam hayati.

KHDTK Wanadipa, dengan luas mencapai 99,65 Ha dan menampung 114 spesies, memegang peran penting dalam upaya konservasi keanekaragaman hayati. Namun, peran ini menghadapi tantangan serius, di mana jenis tanaman lokal semakin sedikit dimanfaatkan dan berisiko tergeser atau hilang akibat digantikan oleh jenis introduksi yang tumbuh cepat [1]. Oleh karena itu, identifikasi tanaman yang akurat menjadi krusial, namun upaya ini masih terkendala oleh minimnya data citra maupun model *deep learning* yang secara khusus mampu mengidentifikasi tanaman khas Indonesia secara akurat dan efisien. Dengan kata lain, kemampuan identifikasi ini membantu mengarahkan pengelolaan hutan agar tidak hanya mempertimbangkan sisi komersial, tetapi juga menjamin kelestarian hasil dan fungsi sosial-ekologis kawasan tersebut. Fungsi sosial ekologis yang dimaksud mencakup peran kawasan sebagai sarana edukasi dan wisata bagi masyarakat sekitar, sekaligus sebagai penopang konservasi keanekaragaman hayati serta jasa lingkungan hutan.

Meskipun memiliki peran vital, upaya identifikasi tanaman di KHDTK saat ini masih menghadapi kendala operasional yang signifikan. Proses identifikasi sebagian besar masih dilakukan secara manual dan sangat bergantung pada

ketersediaan pakar botani. Hal ini menciptakan keterbatasan akses informasi bagi masyarakat sekitar dan pengunjung yang ingin mempelajari keanekaragaman hayati secara mandiri. Akibatnya, keseluruhan proses untuk mengenali suatu spesies tanaman menjadi lambat dan tidak efisien untuk mendukung kebutuhan edukasi dan konservasi yang cepat.

Untuk mengatasi kendala ini, teknologi *deep learning* seperti *Convolutional Neural Networks* (CNN) menawarkan solusi canggih, di mana CNN telah terbukti merevolusi klasifikasi penyakit tanaman dengan mengatasi keterbatasan metode tradisional [2]. Namun, mayoritas penelitian di bidang ini cenderung berfokus penuh pada pencapaian akurasi setinggi mungkin, seringkali dengan mengabaikan aspek efisiensi komputasi. Model deteksi *real-time* yang ringan dan cepat juga belum banyak dieksplorasi untuk konteks identifikasi tanaman di lapangan. Akibatnya, keseimbangan (*trade-off*) antara akurasi dan efisiensi komputasi yang sangat penting untuk aplikasi praktis belum banyak diteliti secara sistematis.

Kebutuhan akan efisiensi komputasi ini menjadi semakin relevan mengingat rencana implementasi akhir sistem identifikasi tanaman pada platform berbasis web yang ditujukan untuk diakses secara luas oleh pengunjung dan masyarakat sekitar KHDTK. Sebagai layanan publik yang dikelola oleh institusi pendidikan, sistem ini perlu mampu melayani permintaan dari banyak pengguna secara bersamaan tanpa memerlukan infrastruktur server berkapasitas besar, sekaligus tetap responsif bagi pengguna yang mengakses melalui perangkat dengan spesifikasi terbatas atau koneksi internet yang tidak selalu stabil. Oleh karena itu, model yang terlalu kompleks secara komputasi, meskipun mungkin unggul dari sisi akurasi, berpotensi kurang praktis untuk diterapkan pada konteks penggunaan seperti ini, sehingga pemilihan arsitektur yang mempertimbangkan keseimbangan antara akurasi dan efisiensi komputasi menjadi kebutuhan yang mendasar, bukan sekadar pertimbangan teknis tambahan

Menjawab tantangan tersebut, penelitian ini mengusulkan penggunaan arsitektur YOLOv5 sebagai model dasar. Pilihan ini didasari oleh reputasi YOLOv5 yang cepat, akurat, dan sangat cocok untuk *deployment* aplikasi *real-time*, bahkan performanya terbukti mampu mengungguli YOLOv7 dalam berbagai metrik

akurasi [3]. Fokus utama penelitian ini adalah melakukan modifikasi pada *backbone* model untuk menemukan *sweet spot* ideal yang menyeimbangkan antara akurasi tinggi dan efisiensi komputasi. Pada akhirnya, model optimal yang ditemukan akan diintegrasikan ke dalam sistem informasi berbasis web, sehingga dapat diakses dengan mudah oleh masyarakat dan pengunjung KHDTK.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, berikut adalah rumusan masalah yang akan dibahas pada tugas akhir ini:

1. Bagaimana merancang fitur klasifikasi tanaman berbasis daun yang dapat diakses oleh masyarakat dan pengunjung sekitar melalui aplikasi web?
2. Model seperti apa yang mampu memberikan keseimbangan antara akurasi tinggi dan efisiensi komputasi untuk mendukung kebutuhan sistem klasifikasi tanaman tersebut?
3. Bagaimana performa model terbaik dalam skenario *deployment real-time* di lingkungan KHDTK?

1.3 Batasan Masalah

Untuk menjaga fokus dan kesesuaian dengan tujuan, ruang lingkup penelitian tugas akhir ini dibatasi. Berikut adalah batasan masalah yang ditetapkan:

1. Lingkup *dataset* yang digunakan untuk pelatihan dan evaluasi model terbatas pada 13 kelas (spesies) tanaman yang dikoleksi secara spesifik dari area pelataran kantor KHDTK Wanadipa.
2. Modifikasi arsitektur yang diimplementasikan difokuskan secara eksklusif pada substitusi modul *backbone* (yakni EfficientNet, MobileNet, ResNet, dan VGG), sementara struktur *neck* (FPN dan PAN) dan *head* asli dari YOLOv5 dipertahankan untuk menjaga konsistensi perbandingan.
3. Seluruh proses pelatihan model, termasuk lingkungan komputasi (*hardware*) dan konfigurasi *hyperparameter* (seperti *learning rate, batch size*, dan jumlah *epoch*), diseragamkan untuk menjamin validitas dan keadilan (*fairness*) dalam perbandingan performa antar model.

4. Evaluasi performa akurasi model difokuskan pada metrik standar deteksi objek (Precision, Recall, mAP@0.5, dan mAP@0.5:0.95), sementara efisiensi komputasi diukur secara kuantitatif menggunakan Giga Floating Point Operations (GFLOPs), yaitu metrik jumlah operasi hitung yang dibutuhkan model untuk satu kali inferensi, sebagai indikator kelayakan model untuk aplikasi waktu nyata atau perangkat dengan sumber daya terbatas.
5. Implementasi model terbaik terbatas pada pengembangan prototipe aplikasi berbasis web; penelitian ini tidak mencakup pengujian, optimalisasi, atau *deployment* pada perangkat *mobile* maupun *edge device*.

1.4 Tujuan Penelitian

Tujuan utama dari penelitian ini adalah melakukan rekonstruksi arsitektur YOLOv5 dengan mengimplementasikan empat variasi *backbone* CNN yang berbeda, yaitu EfficientNetB1, ResNet152, VGG16-BN, dan MobileNet-Large. Setelah model berhasil dibangun, akan dilakukan analisis performa komparatif untuk mengevaluasi *trade-off* (keseimbangan) antara akurasi dan efisiensi komputasi pada setiap model. Evaluasi ini menggunakan metrik *Precision*, *Recall*, *mean Average Precision* (mAP@0.5 dan mAP@0.5:0.95), serta Giga *Floating Point Operations* (GFLOPs) untuk menentukan *backbone* terbaik bagi sistem klasifikasi daun di KHDTK. Sebagai tahap akhir, model dengan performa paling optimal tersebut akan diimplementasikan dan diuji ke dalam sebuah sistem informasi tanaman berbasis web guna mendukung kebutuhan identifikasi tanaman di lingkungan KHDTK Wanadipa.

1.5 Manfaat Penelitian

Manfaat penelitian bagi KHDTK Wanadipa, sebagai *stakeholder,* sebagai berikut:

1. Mendukung pengelolaan digital tanaman dengan basis data terintegrasi.
2. Mempercepat proses identifikasi tanaman tanpa harus menunggu pakar.
3. Menjadi basis pengembangan sistem *monitoring* ekosistem hutan kampus.

Manfaat penelitian bagi warga sekitar dan pengunjung KHDTK Wanadipa adalah sebagai berikut:

1. Memberikan edukasi mengenai jenis tanaman lokal secara interaktif.
2. Membantu masyarakat sekitar dalam proses pembibitan atau identifikasi tanaman dengan cara yang mudah.
3. Meningkatkan kesadaran pelestarian keanekaragaman hayati di kawasan hutan kampus.

1.6 Metode Penelitian

Terdapat beberapa tahapan dalam pelaksanaan Tugas Akhir ini. Berikut merupakan tahapan dalam pembuatan Tugas Akhir.

1. Studi Literatur

Tahap awal penelitian dimulai dengan studi literatur yang komprehensif untuk membangun landasan teoretis yang kuat. Kegiatan ini berfokus pada pengumpulan dan peninjauan penelitian-penelitian sebelumnya yang relevan dengan topik klasifikasi tanaman, deteksi objek, dan arsitektur *deep learning*. Kajian pustaka ini mencakup perbandingan model-model seperti CNN, YOLO, ResNet, dan EfficientNet, serta analisis metode yang telah ada. Tujuannya adalah untuk mengidentifikasi celah penelitian (*research gap*), memahami *state-of-the-art*, dan memvalidasi pemilihan arsitektur YOLOv5 sebagai dasar penelitian.

2. Merancang Alur Penelitian

Setelah studi literatur, langkah selanjutnya adalah merancang alur penelitian secara sistematis untuk memastikan penelitian berjalan terstruktur. Tahapan ini mencakup penetapan langkah-langkah metodologis yang akan diambil, mulai dari akuisisi data, pra-pemrosesan, perancangan arsitektur model, hingga tahap evaluasi akhir. Alur penelitian ini berfungsi sebagai peta jalan (*roadmap*) yang memandu seluruh proses, memastikan bahwa setiap fase dilaksanakan secara logis dan berurutan. Dengan perancangan yang matang, penelitian diharapkan dapat berjalan secara efisien dan fokus untuk menjawab rumusan masalah yang telah ditetapkan.

3. Mengumpulkan Dan Pembersihan Data

Tahap pengumpulan data dilakukan secara langsung di pelataran kantor KHDTK Wanadipa, dengan fokus pada 13 jenis tanaman yang telah ditentukan. Pengambilan gambar menggunakan dua metode, yaitu pemotretan daun secara individual dengan latar belakang netral dan pemotretan daun langsung di pohon dalam kondisi pencahayaan natural. Dari proses ini, terkumpul 631 gambar daun sehat yang kemudian diberi anotasi *bounding box* menggunakan platform Roboflow. Untuk memperkaya variasi *dataset* dan mencegah *overfitting*, dilakukan augmentasi data (meliputi *flip*, rotasi, dan *zoom*) sehingga total *dataset* akhir mencapai 1.553 gambar, yang kemudian dibagi menjadi data latih (86%), validasi (9%), dan uji (5%).

4. Perancangan Arsitektur Model

Perancangan arsitektur model dalam penelitian ini menggunakan YOLOv5 sebagai kerangka kerja dasar. Fokus utama modifikasi adalah pada substitusi modul *backbone*, di mana empat arsitektur CNN populer dieksperimenkan, yaitu EfficientNetB1, ResNet152, VGG16-BN, dan MobileNet-Large. Untuk memastikan perbandingan yang adil dan menjaga kompatibilitas, struktur *neck* (menggunakan FPN dan PAN) serta *head* deteksi dari YOLOv5 asli dipertahankan pada semua varian model. Seluruh *layer* dari *backbone* yang diintegrasikan tidak dibekukan (*unfrozen*) agar dapat beradaptasi sepenuhnya dengan *dataset* daun selama proses pelatihan.

5. Melatih Model

Proses pelatihan untuk setiap model yang diuji dilakukan dalam lingkungan komputasi yang terkontrol dan seragam untuk menjamin keadilan perbandingan. Pelatihan dijalankan di atas *hardware* NVIDIA A100-SXM4-80GB, di mana setiap model dilatih selama 300 *epoch* dengan ukuran gambar input 640x640. Konfigurasi *hyperparameter* krusial, seperti *optimizer* SGD, *learning rate* 0.01, dan parameter *loss function*, dijaga tetap identik di semua eksperimen. Penyeragaman kondisi pelatihan ini sangat penting untuk memastikan bahwa perbedaan performa yang teramati murni disebabkan oleh perbedaan arsitektur *backbone*.

6. Analisis Dan Evaluasi Hasil

Tahap akhir dari metodologi ini adalah analisis dan evaluasi hasil secara kuantitatif terhadap semua model yang telah dilatih. Evaluasi performa dilakukan pada *test set* yang sama, menggunakan metrik akurasi standar deteksi objek seperti *Precision*, *Recall*, mAP@0.5 (IoU > 0.5), dan mAP@0.5:0.95 (IoU 0.5 s.d. 0.95). IoU atau Intersection over Union merupakan rasio tumpang tindih antara kotak prediksi dan kotak sebenarnya, sehingga mAP@0.5 hanya mensyaratkan tumpang tindih minimal 50 persen, sedangkan mAP@0.5:0.95 adalah rata rata performa pada sepuluh ambang IoU sekaligus dari 0.5 hingga 0.95, sehingga penilaiannya jauh lebih ketat. Selain akurasi, efisiensi komputasi juga diukur secara ketat menggunakan Giga Floating Point Operations (GFLOPs) untuk menilai kompleksitas dan kebutuhan sumber daya model. Analisis ini difokuskan pada perbandingan *trade-off* antara akurasi dan efisiensi untuk menentukan model dengan arsitektur *backbone* terbaik untuk *deployment*.

1.7 Sistematika Penulisan

Berikut adalah sistematika penulisan yang digunakan dalam penelitian ini:

BAB I PENDAHULUAN

Bab ini menyajikan gambaran umum penelitian, yang mencakup latar belakang masalah mengenai urgensi identifikasi tanaman di KHDTK Wanadipa dan celah penelitian yang ada. Bagian ini juga merinci rumusan masalah, batasan masalah, tujuan, serta manfaat yang diharapkan dari penelitian.

BAB II KAJIAN PUSTAKA

Bab ini berisi tinjauan mendalam terhadap penelitian-penelitian sebelumnya yang relevan dan menjadi landasan teoretis penelitian. Selain itu, dipaparkan pula dasar-dasar teori mengenai deteksi objek, arsitektur YOLOv5, varian *backbone* CNN yang digunakan, serta metrik evaluasi performa.

BAB III METODE PENELITIAN

Bab ini menguraikan langkah-langkah sistematis yang dilakukan untuk mencapai tujuan penelitian, dimulai dari studi literatur dan perancangan alur. Tahapan ini mencakup proses pengumpulan data, perancangan arsitektur model, skenario pelatihan, hingga metode analisis dan evaluasi hasil.

BAB IV HASIL DAN PEMBAHASAN

Bab ini memaparkan seluruh hasil eksperimen yang telah dilakukan, termasuk penyajian data performa akurasi dan efisiensi dari setiap model. Selanjutnya, dilakukan pembahasan dan analisis komparatif secara mendalam terhadap hasil tersebut untuk menentukan model terbaik.

BAB V KESIMPULAN DAN SARAN

Bab ini merupakan penutup yang berisi rangkuman kesimpulan yang ditarik dari hasil analisis dan pembahasan. Bagian ini juga mencantumkan saran dan rekomendasi untuk penelitian selanjutnya berdasarkan temuan dan keterbatasan yang ada dalam studi ini.

BAB II
KAJIAN PUSTAKA

2.1 Penelitian Terdahulu

Kajian pustaka ini dilakukan untuk memetakan penelitian-penelitian terkini yang relevan dengan identifikasi tanaman menggunakan metode *deep learning*. Tinjauan ini berfokus pada tiga pilar utama: (1) aplikasi *Convolutional Neural Networks* (CNN) murni untuk klasifikasi citra daun, (2) penggunaan arsitektur deteksi objek modern seperti YOLO dan implementasi hibridanya, serta (3) studi komparatif yang menganalisis performa berbagai *backbone* (misalnya EfficientNet, ResNet, VGG) dalam konteks efisiensi dan akurasi. Tinjauan ini menjadi landasan untuk mengidentifikasi celah penelitian dan memvalidasi pendekatan yang diusulkan dalam studi ini. Meskipun ketiga pilar ini masing masing telah banyak dieksplorasi secara terpisah, penelitian yang secara eksplisit mengintegrasikan analisis efisiensi komputasi ke dalam kerangka deteksi objek untuk kasus identifikasi tanaman lokal Indonesia masih tergolong terbatas. Rangkuman dari kajian pustaka dapat dilihat pada Tabel 2.1 berikut.

Penelitian ini berfokus mengatasi kesulitan identifikasi daun secara manual dengan menerapkan Convolutional Neural Network (CNN) [4]. Penelitian ini menggunakan *dataset* komprehensif yang terdiri dari 33 kelas daun dengan total 21.450 citra, yang dibagi untuk data pelatihan, validasi, dan pengujian. Hasilnya menunjukkan bahwa model CNN yang dikombinasikan dengan *data augmentation* dan *transfer learning* berhasil mencapai akurasi pelatihan 94% dan akurasi pengujian 84%. Studi ini menyimpulkan bahwa kombinasi teknik tersebut secara signifikan meningkatkan kemampuan generalisasi model dan memberikan hasil klasifikasi yang lebih stabil dibandingkan CNN tradisional. Meskipun demikian, penelitian ini masih berfokus pada pendekatan klasifikasi citra tunggal dan belum mengeksplorasi kemampuan lokalisasi objek yang relevan untuk skenario multi-daun dalam satu citra.

Mengembangkan pendekatan tersebut lebih lanjut, sebuah studi komparatif dilakukan untuk membandingkan performa lima model transfer learning

(MobileNet, VGG16, DenseNet121, ResNet50V2, dan NASNetMobile) dalam mengidentifikasi 10 jenis tanaman obat Indonesia [5]. Dari kelima model tersebut, MobileNet memberikan hasil terbaik dengan mencatatkan akurasi 98.86%, serta nilai *precision* dan F1-score tertinggi. Eksperimen juga menunjukkan bahwa penerapan teknik augmentasi data mampu meningkatkan performa model secara signifikan hingga ±5% dibandingkan dengan data tanpa augmentasi. Penelitian ini menegaskan efektivitas penggunaan model *transfer learning* yang ringan (*lightweight*) untuk klasifikasi daun, terutama pada kasus *dataset* terbatas dengan citra beresolusi tinggi. Namun demikian, evaluasi pada penelitian ini belum turut mempertimbangkan metrik efisiensi komputasi seperti FLOPs, sehingga trade-off antara akurasi dan beban komputasi model belum sepenuhnya terungkap.

Sebagai alternatif dari pendekatan berbasis deep learning tersebut, pendekatan identifikasi daun berbasis ekstraksi fitur manual yang mencakup aspek tekstur, warna, dan kerapatan vena juga diajukan [6]. Penelitian ini menggunakan *dataset* Flavia yang populer (32 spesies, 1907 gambar) dengan *Support Vector Machine* (SVM) sebagai *classifier* utamanya. Hasil terbaik diperoleh dengan menggabungkan ketiga set fitur tersebut (tekstur, warna, dan vena), yang berhasil mencapai akurasi klasifikasi sebesar 84.46%. Studi ini menunjukkan pentingnya penggabungan multi-fitur visual untuk meningkatkan akurasi identifikasi dibandingkan jika hanya mengandalkan satu jenis fitur saja. Meskipun demikian, pendekatan berbasis fitur manual ini cenderung kurang scalable dibandingkan pendekatan deep learning ketika diterapkan pada dataset dengan variasi kondisi pengambilan gambar yang lebih kompleks.

Beralih ke pilar kedua tinjauan ini, yaitu penggunaan arsitektur deteksi objek modern beserta implementasi hibridanya, untuk menyelesaikan masalah klasifikasi varietas ganja Thailand yang memiliki kemiripan visual tinggi, diusulkan model hibrida YOLOv5 + CNN [7]. Penelitian ini menggunakan *dataset* berisi 2829 gambar dari 8 kelas varietas, yang telah melalui proses segmentasi dan augmentasi. Model hibrida yang diusulkan berhasil mencapai akurasi 95.37%, terbukti mengungguli arsitektur model tunggal seperti VGG16 (93.56%) dan InceptionV3 (91.56%). Kombinasi antara YOLO untuk deteksi lokasi fitur dan

CNN untuk klasifikasi *fine-grained* terbukti efektif meningkatkan akurasi sekaligus efisiensi waktu inferensi. Studi ini menegaskan bahwa pendekatan hibrida deteksi dan klasifikasi berpotensi diadaptasi untuk kasus identifikasi tanaman lain yang memiliki tingkat kemiripan visual antar kelas yang tinggi.

Pada domain yang lebih luas, arsitektur CNN konvensional dan EfficientNet turut digabungkan untuk menciptakan model hibrida yang bertujuan meningkatkan performa pengenalan objek pada citra yang kompleks [8]. Model hibrida ini diuji pada *dataset* COCO dan menunjukkan peningkatan performa tanpa memperbesar ukuran model secara signifikan. Akurasi terbukti meningkat sebesar 4% dibandingkan dengan CNN konvensional, dengan waktu inferensi yang lebih cepat pada GPU dengan sumber daya terbatas. Hasil ini menunjukkan bahwa pendekatan hibrida efektif dalam menjaga keseimbangan (*trade-off*) antara akurasi dan efisiensi komputasi. Temuan ini memperkuat argumen bahwa integrasi *backbone* ringan seperti EfficientNet ke dalam arsitektur deteksi objek dapat dilakukan tanpa mengorbankan performa secara signifikan, sejalan dengan pendekatan yang diadopsi pada penelitian ini.

Pendekatan hibrida serupa turut diterapkan pada domain inspeksi industri, di mana model Hybrid YOLOv5x yang diintegrasikan dengan ResNet 18 dikembangkan untuk mendeteksi cacat isolator dari citra yang diambil menggunakan UAV [9]. Dalam arsitektur ini, YOLOv5x digunakan untuk deteksi objek, sementara ResNet-18 bertugas untuk klasifikasi *fine-grained* pada cacat yang ditemukan. Hasil penelitian menunjukkan peningkatan mAP sebesar 6% dibandingkan dengan model YOLOv5x standar, sementara waktu inferensi tetap terjaga cepat. Kombinasi ini terbukti efektif untuk aplikasi inspeksi otomatis *real-time* dengan tingkat kesalahan rendah di lingkungan *outdoor*. Keberhasilan penerapan pada domain inspeksi berbasis UAV ini turut mengindikasikan fleksibilitas arsitektur hibrida YOLO untuk diadaptasi pada berbagai konteks deteksi objek di lapangan, termasuk identifikasi tanaman.

Sejalan dengan pilar ketiga tinjauan ini yang berfokus pada efisiensi dan akurasi berbagai backbone, studi komparatif dilakukan pada empat arsitektur CNN (ResNet50, EfficientNetB7, InceptionV3, VGG16) untuk identifikasi gulma dan

tanaman, yang bertujuan untuk optimasi sistem pertanian [10]. Hasil penelitian menunjukkan bahwa EfficientNetB7 memberikan performa terbaik dengan akurasi di atas 97%, efisiensi komputasi yang tinggi, dan waktu pelatihan paling singkat. Di sisi lain, ResNet50 menunjukkan stabilitas terbaik terhadap perubahan pencahayaan dan kondisi latar belakang yang bervariasi. Studi ini membuktikan bahwa model *lightweight* seperti EfficientNet sangat efektif untuk digunakan pada aplikasi pertanian *real-time*. Hasil ini memberikan indikasi awal bahwa pemilihan backbone yang tepat dapat memberikan dampak signifikan terhadap keseimbangan akurasi dan efisiensi, sebagaimana menjadi fokus utama pada penelitian ini.

Dalam konteks deteksi cacat industri, diusulkan sebuah model fusi yang menggabungkan EfficientNet dengan Involution operator [11]. Pendekatan ini dirancang untuk meningkatkan kualitas representasi fitur spasial tanpa menambah kompleksitas komputasi model secara signifikan. Hasil eksperimen menunjukkan peningkatan akurasi hingga 96.8% serta peningkatan efisiensi inferensi sebesar 20% dibandingkan dengan penggunaan EfficientNet murni. Model ini terbukti sangat efektif dalam mendeteksi cacat kecil dan kompleks yang sering gagal terdeteksi oleh arsitektur CNN konvensional. Pendekatan fusi arsitektur semacam ini menunjukkan bahwa efisiensi komputasi dan akurasi tidak selalu bersifat trade-off yang ketat, melainkan dapat dioptimalkan secara bersamaan melalui modifikasi arsitektural yang tepat.

Tabel 2. 1 Ringkasan Studi Literatur Terdahulu Berdasarkan Identifikasi Tanaman Berbasis CNN dan Fitur Visual

Penulis (Tahun)	Judul	Tujuan Penelitian	Metodologi Penelitian	Hasil Penelitian
Azizah Nur dkk. (2024)	*Algoritma Deep Learning Untuk Pengenalan Gambar Jenis Daun*	Mengidentifikasi jenis daun berdasarkan gambar menggunakan algoritma CNN.	Convolutional Neural Network (CNN) dengan *data augmentation* dan *transfer learning*. Dataset 33 kelas daun.	Akurasi pelatihan 94%, pengujian 84%. Kombinasi augmentasi + transfer learning menghasilkan model paling stabil dan akurat.
Sarah Salsabila dkk. (2024)	*Comparison of Deep Learning Architectures in Identifying Types of Medicinal Plant Leaf Images*	Membandingkan performa lima arsitektur deep learning untuk klasifikasi daun tanaman obat.	*Transfer learning* pada MobileNet, VGG16, DenseNet121, ResNet50V2, dan NASNetMobile. Dataset Indonesian Herb Leaf 3500 (10 kelas).	Model terbaik MobileNet, akurasi 98.86%. Augmentasi data meningkatkan performa signifikan.
S.W. Athapaththu dkk. (2023)	*Plant Leaf Recognition Using Texture, Colour, and Vein Density Features*	Mengidentifikasi spesies daun berdasarkan fitur tekstur, warna, dan kerapatan vena.	Ekstraksi fitur GLCM, RGB channels, dan vein density; klasifikasi dengan Support Vector Machine (SVM).	Akurasi terbaik 84.46% (gabungan fitur). Fitur vein, tekstur, dan warna berkontribusi besar pada performa sistem.

Tabel 2. 2 Ringkasan Studi Literatur Terdahulu Berdasarkan Deteksi Objek Modern dan Model Hibrida

Penulis (Tahun)	Judul	Tujuan Penelitian	Metodologi Penelitian	Hasil Penelitian
Naresh Kumar Trivedi dkk. (2023)	*Hybrid Deep Learning for Thai Cannabis Plant Classification: YOLO+CNN Approach*	Mengembangkan model hibrida untuk klasifikasi	Kombinasi YOLOv5 untuk deteksi dan CNN untuk klasifikasi fitur	Akurasi 95.37%, lebih unggul dari model CNN tunggal seperti VGG16 dan Inception. Efektif

Tabel 2. 3 Ringkasan Studi Literatur Terdahulu Berdasarkan Deteksi Objek Modern dan Model Hibrida (lanjutan)

Penulis (Tahun)	Judul	Tujuan Penelitian	Metodologi Penelitian	Hasil Penelitian
		varietas ganja Thailand.	daun (8 kelas, 2829 gambar).	untuk aplikasi medis dan industri.
Jashanpreet Singh dkk. (2023)	*Object Recognition in Images Using Hybrid Deep Learning Model*	Menggabungkan CNN dan EfficientNet untuk pengenalan objek kompleks.	Model Hybrid CNN–EfficientNet dengan *fine-tuning* transfer learning (dataset COCO).	Akurasi meningkat ~4% dibanding CNN konvensional; performa efisien pada GPU terbatas.
Bruno José Souzaa dkk. (2023)	*Hybrid-YOLO for Classification of Insulators Defects in Transmission Lines Based on UAV*	Mengembangkan sistem klasifikasi cacat isolator berbasis UAV.	Kombinasi YOLOv5x + ResNet-18 untuk ekstraksi fitur dan klasifikasi.	Model Hybrid-YOLO+ResNet18 meningkatkan mAP 6% dibanding YOLOv5x murni; efisien untuk deteksi cacat real-time.

Tabel 2. 3 Ringkasan Studi Literatur Terdahulu Berdasarkan Efisiensi Komputasi dan Studi Komparatif *Backbone*

Penulis (Tahun)	Judul	Tujuan Penelitian	Metodologi Penelitian	Hasil Penelitian
Naman Mishra dkk. (2023)	*A Comparative Study of ResNet50, EfficientNetB7, InceptionV3, VGG16 Models in Crop and Weed Classification*	Membandingkan performa berbagai arsitektur CNN dalam klasifikasi tanaman dan gulma.	Model CNN: ResNet50, EfficientNetB7, InceptionV3, VGG16; dataset pertanian dengan augmentasi.	EfficientNetB7 memberikan akurasi tertinggi dan efisiensi komputasi terbaik; ResNet50 lebih stabil pada kondisi pencahayaan variatif.
Peng Wang dkk. (2022)	*Metal Defect Detection Models Fused EfficientNet and Involution*	Meningkatkan deteksi cacat logam melalui fusi fitur spasial.	Arsitektur EfficientNet + Involution operator untuk ekstraksi fitur adaptif.	Akurasi 96.8%, efisiensi meningkat 20% dibanding EfficientNet biasa. Efektif untuk deteksi industri berbasis visual.

2.2 Landasan Teori

2.2.1 Object Detection

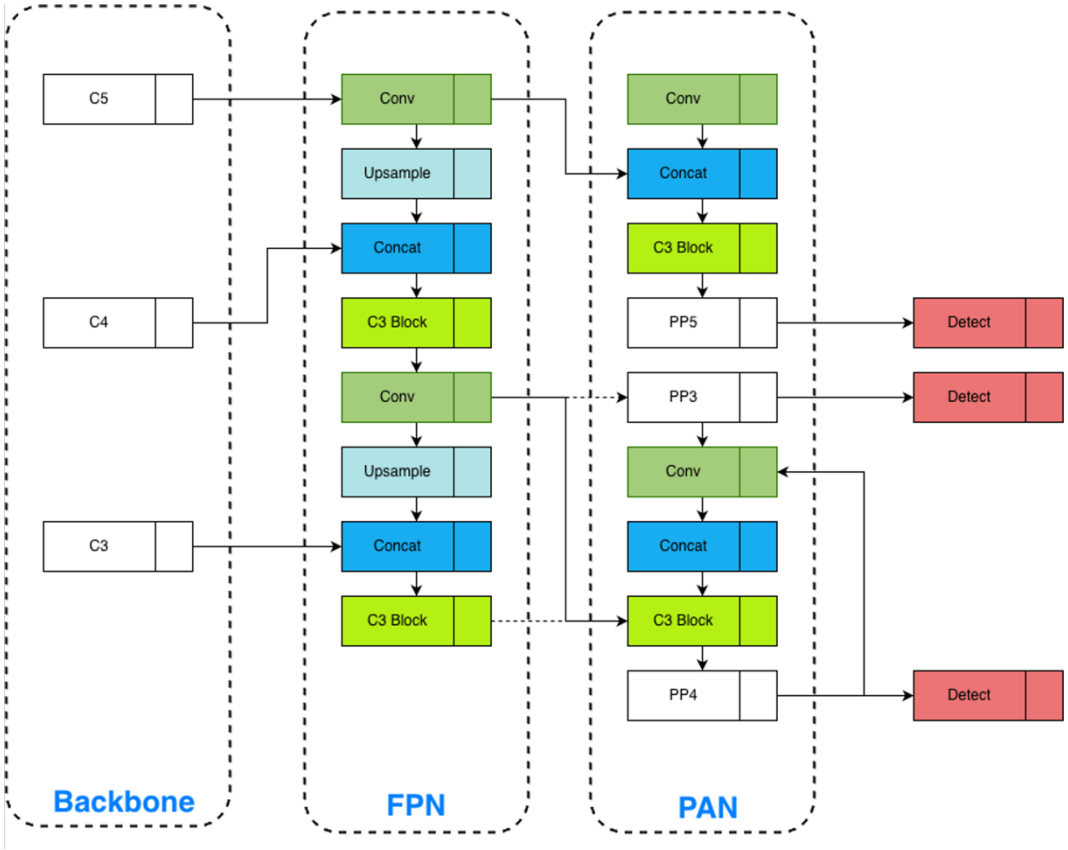
Image classification (klasifikasi citra) merupakan sebuah metode yang memberikan satu label tunggal untuk keseluruhan citra [12]. Pendekatan ini terbukti efektif pada skenario di mana setiap gambar hanya berisi satu jenis tanaman atau penyakit, dan memiliki latar belakang yang relatif sederhana. Sebaliknya, deteksi objek memiliki kemampuan yang lebih canggih, karena tidak hanya mengidentifikasi tetapi juga melokalisasi (menentukan lokasi) beberapa objek sekaligus dalam satu citra [13]. Perbedaan fundamental ini membuat deteksi objek lebih unggul dalam menangani kompleksitas visual yang sering ditemui di dunia nyata.

Dalam konteks pertanian atau lingkungan alaminya (*real-world agricultural settings*), citra yang diambil seringkali berisi beberapa daun, objek yang tumpang tindih, dan latar belakang yang ramai. Untuk kondisi seperti ini, *object detection* umumnya dianggap lebih cocok dan relevan dibandingkan klasifikasi citra standar [14]. Kemampuannya untuk memisahkan dan mengidentifikasi setiap daun secara individual sangat penting untuk akurasi identifikasi di lapangan. Oleh karena itu, penelitian ini memilih pendekatan deteksi objek untuk mengatasi tantangan identifikasi tanaman secara efektif.

2.2.2 YOLOv5

YOLOv5 adalah arsitektur deteksi objek populer yang terstruktur menjadi tiga komponen utama, *Backbone*, *Neck*, dan *Head,* yang terlihat dari Gambar 2.1. *Backbone* bertanggung jawab untuk ekstraksi fitur dari gambar input, biasanya menggunakan *Cross Stage Partial* (CSP) *network* seperti CSPDarknet untuk menangkap fitur *low-level* dan *high-level* secara efisien [15]. Bagian inilah yang menjadi fokus modifikasi dalam penelitian ini, di mana CSPDarknet digantikan dengan empat varian arsitektur backbone lain, yaitu EfficientNetB1, ResNet152, VGG16 BN, dan MobileNet Large, untuk membandingkan pengaruhnya terhadap akurasi dan efisiensi komputasi model. Komponen *Neck* kemudian

menggabungkan *Feature Pyramid Network* (FPN) dan *Path Aggregation Network* (PAN) untuk menggabungkan (fusi) fitur-fitur dari skala yang berbeda.



Gambar 2. 1 Arsitektur model YOLOv5

Head adalah komponen deteksi akhir yang bertugas memprediksi *bounding box* (kotak pembatas), skor *objectness* (keyakinan adanya objek), dan probabilitas kelas untuk setiap objek yang terdeteksi. Arsitektur *head* ini sering menggunakan struktur *decoupled* untuk memisahkan tugas klasifikasi dan lokalisasi guna meningkatkan akurasi. Fungsi kerugian (*loss function*) di YOLOv5 biasanya terdiri dari tiga bagian utama untuk mengoptimalkan model selama pelatihan. Ketiga bagian tersebut adalah *box loss* (mengukur akurasi *bounding box* menggunakan CIoU atau varian lainnya), *objectness loss* (menilai apakah ada objek dalam kotak), dan *classification loss* (mengevaluasi kebenaran kelas yang diprediksi).

2.2.3 ResNet152

Pada jaringan *deep networks* tradisional, penambahan lapisan (*layers*) seringkali ironisnya menyebabkan akurasi pelatihan dan pengujian yang lebih buruk akibat masalah *vanishing gradients* dan kesulitan optimisasi, sebuah fenomena yang dikenal sebagai *degradation problem*. ResNet mengatasi masalah ini dengan memperkenalkan *skip connections* (atau *identity mappings*), yang memungkinkan input dari sebuah lapisan ditambahkan secara langsung ke outputnya [16]. Koneksi pintas ini memungkinkan gradien mengalir lebih mudah melalui jaringan dan menjaga informasi tetap utuh melintasi banyak lapisan. Mekanisme ini memastikan *backpropagation* yang stabil dan membantu menjaga norma gradien, sehingga memungkinkan pelatihan jaringan yang sangat dalam tanpa kehilangan performa.

Varian ResNet-152 (152 lapisan) yang digunakan dalam eksperimen ini dianggap sangat efektif karena mampu memanfaatkan blok residual untuk mempelajari fitur-fitur yang sangat kompleks tanpa mengalami masalah degradasi. Arsitektur ini mencapai akurasi tinggi sambil tetap menjaga efisiensi komputasi, karena *skip connections* memungkinkan model yang lebih dalam tanpa peningkatan kesulitan pelatihan yang proporsional [17]. ResNet-152 menjadi penting karena berhasil menunjukkan bahwa jaringan yang sangat dalam dapat mengungguli jaringan yang lebih dangkal berkat pembelajaran residual [18]. Kemampuannya menangkap fitur kompleks inilah yang membuatnya menjadi kandidat *backbone* yang kuat dalam penelitian ini.

2.2.4 EfficientNetB1

Keunggulan utama EfficientNet terletak pada metode *compound scaling* yang diperkenalkannya, yang secara sistematis dan seragam menskalakan tiga dimensi jaringan: kedalaman (*depth*), lebar (*width*), dan resolusi citra input [19]. Alih-alih hanya meningkatkan satu dimensi secara arbitrer seperti metode sebelumnya, *compound scaling* menggunakan satu set koefisien penskalaan tetap untuk menyeimbangkan ketiga dimensi tersebut secara bersamaan. Pendekatan yang seimbang ini terbukti menghasilkan performa dan efisiensi yang jauh lebih

baik dibandingkan model-model sebelumnya. Ini adalah inovasi inti yang membuat EfficientNet mampu mencapai akurasi tinggi dengan komputasi yang jauh lebih sedikit.

Efisiensi EfficientNet lebih lanjut ditingkatkan oleh penggunaan *Mobile Inverted Bottleneck Convolution* (MBConv), yang menggabungkan *depthwise separable convolutions* dengan *shortcut connections* [20]. Blok MBConv ini secara drastis mengurangi komputasi sambil tetap mempertahankan kemampuan ekstraksi fitur yang kuat. Varian B1 sering dianggap optimal untuk banyak aplikasi praktis karena menawarkan keseimbangan yang kuat antara akurasi dan efisiensi komputasi, memberikan akurasi tinggi tanpa tuntutan sumber daya yang berat seperti B4 atau B7 [19]. Kombinasi *compound scaling* dan MBConv inilah yang membuat B1 sangat menarik untuk penggunaan di dunia nyata di mana sumber daya terbatas.

2.2.5 VGG16-BN

VGG adalah arsitektur *convolutional neural network* yang dikenal karena arsitekturnya yang sangat sederhana dan seragam. Desain intinya hanya menumpuk beberapa lapisan konvolusi 3x3 yang diikuti oleh lapisan *pooling*, sebuah desain yang membuatnya mudah untuk diimplementasikan dan diperluas [21]. Kesederhanaan ini menjadikannya arsitektur dasar yang sangat populer dalam berbagai penelitian *deep learning*. Namun, kedalamannya yang signifikan tanpa mekanisme khusus seperti *skip connections* membuatnya rentan terhadap masalah optimisasi dan *vanishing gradients* selama pelatihan.

Untuk mengatasi masalah tersebut, *Batch Normalization* (BN) sering ditambahkan ke VGG, yang berfungsi menstabilkan dan mempercepat proses pelatihan [22]. BN bekerja dengan menormalisasi aktivasi di setiap lapisan, sehingga mengurangi *internal covariate shift* dan memungkinkan penggunaan *learning rate* yang lebih tinggi secara efektif. Varian VGG16-BN menjadi populer karena mampu mencapai akurasi tinggi sambil menjaga efisiensi komputasi yang wajar [23]. Kombinasi desain yang lugas dan efek stabilisasi dari *batch normalization* menjadikannya model yang andal untuk tugas klasifikasi.

2.2.6 MobileNet-Large

MobileNet adalah arsitektur jaringan saraf yang dirancang khusus untuk perangkat *mobile* dan *edge device* yang memiliki keterbatasan sumber daya. Inovasi intinya adalah penggunaan *depthwise separable convolutions*, yang memecah operasi konvolusi standar menjadi dua langkah terpisah [24]. Dua langkah tersebut adalah *depthwise convolution* (menerapkan satu filter per saluran input) dan *pointwise convolution* (konvolusi 1x1 untuk menggabungkan output antar saluran). Pendekatan ini secara drastis mengurangi jumlah parameter dan biaya komputasi dibandingkan konvolusi tradisional, menjadikan MobileNet sangat ringan dan cepat.

Model MobileNet yang lebih besar, seperti varian "Large" yang menggunakan *width* atau *resolution multiplier* lebih tinggi, umumnya mencapai akurasi yang lebih tinggi karena memiliki lebih banyak parameter [25]. Peningkatan parameter ini memungkinkan model untuk mempelajari fitur-fitur yang lebih kompleks, sambil tetap mempertahankan efisiensi yang jauh lebih besar daripada jaringan tradisional. Arsitektur MobileNet memungkinkan pengguna untuk memilih ukuran model yang paling seimbang antara akurasi dan efisiensi untuk aplikasi spesifik mereka. Versi yang lebih besar (*large*) lebih disukai ketika akurasi yang lebih tinggi diperlukan dan perangkat masih mampu menangani sedikit peningkatan komputasi.

2.2.7 Augmentasi Data

Augmentasi data (*data augmentation*) adalah teknik yang digunakan untuk memperbanyak ukuran dan keragaman dataset pelatihan secara artifisial dengan menerapkan berbagai transformasi pada data asli [26]. Proses ini sangat penting untuk membantu mengurangi *overfitting*, di mana model menjadi terlalu menghafal data pelatihan dan gagal bergeneralisasi pada data baru. Dengan mengekspos model ke lebih banyak variasi contoh, augmentasi data membuatnya lebih cenderung mempelajari pola yang relevan dan meningkatkan kemampuannya untuk beradaptasi pada data yang belum pernah dilihat. Peningkatan variabilitas dataset

ini secara langsung meningkatkan generalisasi dan ketahanan (*robustness*) model terhadap kondisi di dunia nyata.

Transformasi yang umum digunakan meliputi operasi geometris seperti *flip* (membalik), rotasi, dan perbesar, serta operasi optik seperti *blur* (mengaburkan) dan perubahan warna. Metode-metode ini dipilih karena mampu menyimulasikan variasi dunia nyata yang mungkin dihadapi model, seperti perubahan orientasi objek, skala, pencahayaan, atau perspektif. Berbagai perangkat, seperti pustaka Albumentations, menyediakan implementasi yang efisien untuk menerapkan augmentasi ini dalam alur kerja pelatihan [27]. Teknik-teknik ini menjadi sangat berharga terutama ketika data berlabel terbatas, karena membantu model mencapai akurasi dan ketahanan yang lebih tinggi tanpa perlu mengumpulkan lebih banyak data.

2.2.8 Roboflow

Roboflow adalah platform berbasis *cloud* yang dirancang untuk menyederhanakan dan mempercepat alur kerja proyek *computer vision*, mulai dari manajemen dataset, pra-pemrosesan gambar, hingga augmentasi data. Platform ini menyediakan serangkaian *tools* terintegrasi untuk mengorganisasi dan melabeli dataset gambar dalam jumlah besar, sehingga mempermudah proses persiapan data sebelum melatih model *machine learning*. Selain itu, Roboflow juga mendukung berbagai langkah pra-pemrosesan esensial seperti pengubahan ukuran (*resizing*), pemotongan (*cropping*), dan penyesuaian kontras. Seluruh fitur ini bertujuan untuk menstandarkan gambar input dan pada akhirnya meningkatkan performa serta akurasi model yang dilatih.

2.2.9 Metrik Evaluasi

Precision dan *Recall* merupakan dua metrik dasar yang digunakan untuk mengevaluasi performa model deteksi objek. *Precision* mengukur proporsi prediksi positif yang benar benar tepat, sedangkan *Recall* mengukur proporsi objek sebenarnya yang berhasil terdeteksi oleh model, dan keduanya dihitung berdasarkan klasifikasi setiap prediksi sebagai *true positive*, *false positive*, atau

false negative [28]. Untuk menentukan apakah suatu prediksi tergolong benar, digunakan *Intersection over Union* (IoU), yaitu rasio antara luas area tumpang tindih dan luas area gabungan dari kotak prediksi dan kotak sebenarnya, yang menjadi dasar penentuan ambang batas kebenaran deteksi pada hampir seluruh metrik evaluasi deteksi objek [28].

Mean Average Precision (mAP) merupakan metrik akurasi standar yang dihitung dari luas area di bawah kurva hubungan antara *Precision* dan *Recall*, kemudian dirata ratakan pada seluruh kelas yang dievaluasi [28]. mAP@0.5 menghitung nilai mAP dengan ambang batas IoU tetap sebesar 0,5, sedangkan mAP@0.5:0.95 merupakan protokol evaluasi yang lebih ketat, yang dihitung dengan merata ratakan nilai mAP pada sepuluh ambang batas IoU berbeda, mulai dari 0,5 hingga 0,95 dengan interval 0,05, sebagaimana pertama kali diperkenalkan pada protokol evaluasi *dataset* Microsoft COCO [29]. Protokol mAP@0.5:0.95 ini kini menjadi standar umum dalam mengevaluasi model deteksi objek karena mampu merepresentasikan akurasi lokalisasi model secara lebih menyeluruh dibandingkan mAP@0.5 saja.

Selain metrik akurasi, efisiensi komputasi suatu model umumnya diukur menggunakan *Floating Point Operations* (FLOPs atau GFLOPs dalam satuan miliar), yaitu metrik teoritis yang menghitung jumlah operasi matematis yang dibutuhkan model untuk memproses satu input, sehingga bersifat independen terhadap perangkat keras maupun implementasi perangkat lunak yang digunakan [19]. Sebagai pelengkap, *Frames Per Second* (FPS) digunakan untuk mengukur kecepatan inferensi secara empiris, dihitung dari jumlah gambar yang dapat diproses model dalam satu detik pada perangkat keras tertentu, dan pertama kali dipopulerkan sebagai metrik utama performa waktu nyata (*real-time*) pada arsitektur YOLO [30]. Meskipun GFLOPs dan FPS sama sama merepresentasikan efisiensi komputasi, kedua metrik ini tidak selalu berbanding lurus satu sama lain, karena FPS turut dipengaruhi oleh faktor eksternal seperti tingkat optimasi implementasi dan karakteristik perangkat keras, sehingga keduanya perlu dilaporkan secara terpisah untuk memberikan gambaran efisiensi yang lebih menyeluruh dan tidak menyesatkan [31].

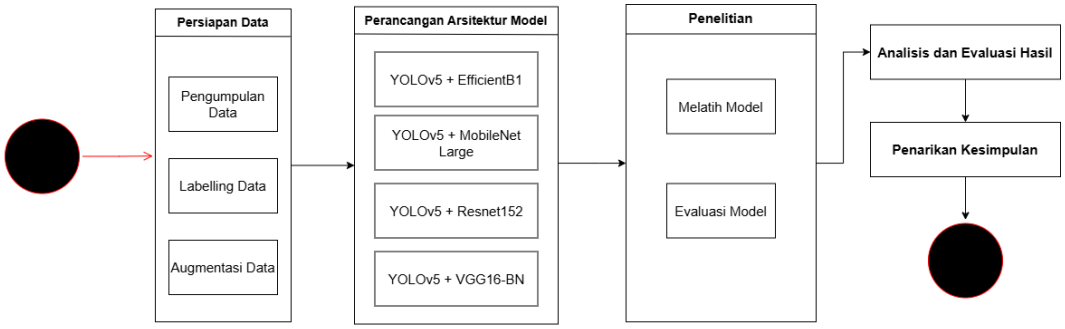
Untuk mengukur keseimbangan antara akurasi dan efisiensi komputasi secara kuantitatif, penelitian ini menggunakan Nilai Efisiensi, yang dihitung dari rasio antara mAP dan GFLOPs. Pendekatan mengukur efisiensi melalui rasio akurasi terhadap biaya komputasi ini merujuk pada prinsip umum yang banyak diterapkan dalam literatur perancangan arsitektur efisien, seperti pada EfficientNet, yang secara eksplisit mengevaluasi model berdasarkan pencapaian akurasi tertinggi untuk setiap satuan FLOPs yang digunakan [19]. Semakin tinggi nilai efisiensi suatu model, semakin besar akurasi yang mampu dihasilkan untuk setiap satuan biaya komputasi yang dikeluarkan, sehingga metrik ini menjadi indikator praktis untuk menentukan arsitektur yang paling optimal untuk *deployment* pada aplikasi dengan keterbatasan sumber daya.

BAB III
METODE PENELITIAN

Bab ini akan menguraikan secara rinci metodologi yang digunakan untuk menjawab tujuan penelitian, yang dimulai dengan penjelasan alur penelitian (3.1). Tahapan metodologi mencakup persiapan data (3.2), yang merinci proses pengumpulan, pelabelan, hingga augmentasi dataset 13 jenis tanaman. Selanjutnya, akan dijelaskan perancangan arsitektur model (3.3) yang membandingkan empat *backbone* CNN (EfficientNetB1, ResNet152, VGG16-BN, MobileNet-Large) pada arsitektur YOLOv5. Bab ini juga merinci konfigurasi *hyperparameter* dan lingkungan yang digunakan untuk melatih model (3.4), serta ditutup dengan pemaparan metrik dan prosedur untuk analisis dan evaluasi hasil (3.5) guna menentukan model dengan *trade-off* terbaik.

3.1 Merancang Alur Penelitian

Penelitian ini dimulai dengan tahap persiapan data, yang mencakup tiga langkah utama: pengumpulan data citra daun di KHDTK, pelabelan data menggunakan *bounding box*, dan augmentasi data untuk meningkatkan variasi dataset. Tahap selanjutnya adalah perancangan arsitektur model, di mana arsitektur dasar YOLOv5 dimodifikasi dengan mengintegrasikan empat varian *backbone* yang berbeda, yaitu EfficientNetB1, MobileNet-Large, ResNet152, dan VGG16-BN. Setelah arsitektur dirancang, penelitian dilanjutkan dengan melatih seluruh model menggunakan parameter yang seragam dan mengevaluasi performa akurasi serta efisiensinya. Sebagai tahap penutup, hasil dari evaluasi tersebut dianalisis secara komprehensif untuk membandingkan *trade-off* dan ditarik kesimpulan guna menentukan *backbone* yang paling optimal.



Gambar 3. 1 Diagram Alur Penelitian

3.2 Persiapan Data

Untuk menjawab kebutuhan akan dataset dan model identifikasi tanaman khas Indonesia yang masih terbatas, tahap persiapan dataset dimulai dengan proses pengumpulan data lapangan yang berfokus pada 13 jenis tanaman spesifik yang berlokasi di pelataran kantor KHDTK. Untuk mendapatkan variasi data, pengambilan gambar dilakukan menggunakan dua metode akuisisi yang berbeda: (1) pemotretan individual, yaitu satu daun difoto dengan latar belakang kertas putih untuk menghasilkan fitur yang jelas dan bebas gangguan latar, dengan satu gambar mewakili satu daun, dan (2) pemotretan *in situ*, yaitu pemotretan yang dilakukan langsung pada pohonnya dengan jarak pengambilan tidak lebih dari 30 cm, di mana setiap gambar pada metode ini dapat menangkap beberapa daun sekaligus dari tanaman yang sama. Kedua metode ini digabungkan karena saling melengkapi, metode kertas putih menghasilkan citra dengan fitur daun yang bersih dan terisolasi sehingga mendukung pembelajaran fitur dasar yang stabil, sementara metode *in situ* merepresentasikan kondisi nyata di lapangan seperti variasi pencahayaan, latar belakang kompleks, dan sudut pandang, sehingga meningkatkan kemampuan generalisasi model saat diterapkan pada aplikasi identifikasi di lapangan

Seluruh proses pengambilan data memanfaatkan pencahayaan natural dari matahari dan hanya menargetkan daun yang berada dalam kondisi sehat, tidak sobek atau terserang hama. Metode pertama menghasilkan total 380 gambar, sedangkan metode kedua menghasilkan total 251 gambar, dengan total keseluruhan data orisinal yang terkumpul sebanyak 631 gambar. Selain jumlah gambar, turut dicatat pula jumlah bounding box, yaitu kotak pembatas yang menandai lokasi

objek daun pada suatu gambar sebagai anotasi untuk keperluan pelatihan model deteksi objek.

Tabel 3. 1 Distribusi Data Sebelum Augmentasi

No	Nama Kelas	Jumlah Metode 1	Jumlah Metode 2	Jumlah Gambar	Jumlah Bounding Boxes
1	Alpukat	0	40	40	595
2	Asam Jawa	17	17	34	117
3	Beringin	30	0	30	30
4	Duet	23	24	47	58
5	Gayam	52	41	93	149
6	Jenetri	19	0	19	19
7	Kelengkeng	19	29	48	90
8	Kendal	18	30	48	70
9	Matoa	67	42	109	183
10	Nangka	55	6	61	65
11	Pete	12	11	23	27
12	Pronojiwo	30	11	41	72
13	Trembesi	38	0	38	38

Pada kelas alpukat, metode 1 tidak dilakukan karena pohon alpukat yang sudah dewasa memiliki tinggi yang membuat daunnya sulit dijangkau untuk dipetik, sementara pohon yang masih muda dinilai terlalu dini untuk diambil daunnya agar tidak mengganggu pertumbuhannya, sehingga seluruh data alpukat diperoleh melalui pemotretan in situ. Hal ini pula yang menjelaskan mengapa kelas alpukat hanya memiliki 40 gambar namun jumlah *bounding box* paling banyak di antara seluruh kelas, karena setiap foto in situ mampu menangkap banyak daun sekaligus dalam satu gambar. Sebaliknya, pada beberapa kelas seperti jenetri dan trembesi, metode 2 tidak dilakukan karena tinggi pohon menyebabkan pengambilan gambar dari jarak jauh menurunkan kualitas citra yang dihasilkan, sehingga pengumpulan data untuk kelas kelas tersebut hanya mengandalkan metode pemotretan individual.

Setelah data terkumpul, proses selanjutnya adalah pelabelan (*labelling*) yang dilakukan menggunakan *software* Roboflow untuk menandai *bounding box* pada setiap daun yang terdeteksi. Mengingat jumlah data orisinal yang terbatas (631 gambar), dilakukan proses augmentasi data untuk memperbanyak dataset dan

mencegah *overfitting*. Augmentasi yang diterapkan meliputi transformasi geometris seperti *flip* (horizontal), rotasi 90°, rotasi acak dengan interval -15° hingga +15°, serta pembesaran (*zoom*). Proses ini berhasil meningkatkan jumlah total dataset menjadi 1.553 gambar, yang kemudian dibagi dengan proporsi 86% untuk data latih (*train*), 9% untuk data validasi (*valid*), dan 5% untuk data uji (*test*), di mana proporsi data latih yang besar dipilih untuk memaksimalkan paparan data pada model. Rincian jumlah gambar hasil augmentasi per kelas dan per pembagian data dapat dilihat pada Tabel 3.2.

Tabel 3. 2 Distribusi Data Setelah Augmentasi

No	Kelas	Data			Total
		Latih	Validasi	Uji	
1	Alpukat	93	5	4	102
2	Asam Jawa	78	5	3	86
3	Beringin	63	7	2	72
4	Duet	108	8	3	119
5	Gayam	204	20	5	229
6	Jenetri	42	3	2	47
7	Kelengkeng	108	10	2	120
8	Kendal	108	8	4	120
9	Matoa	228	22	11	261
10	Nangka	120	15	6	141
11	Pete	45	5	3	53
12	Pronojiwo	93	7	3	103
13	Trembesi	93	5	2	100
	Total	1.383	120	50	1.553

3.3 Perancangan Arsitektur Model

Perancangan arsitektur model dalam penelitian ini menggunakan arsitektur dasar YOLOv5 yang dimodifikasi pada bagian *backbone* (pengekstrak fitur). Eksperimen ini secara spesifik membandingkan empat varian *backbone* CNN populer, yaitu EfficientNetB1, ResNet152, VGG16-BN, dan MobileNet-Large, yang dipilih untuk mewakili karakteristik arsitektur yang beragam. EfficientNetB1 dan MobileNet-Large mewakili arsitektur ringan (*lightweight*) yang dioptimalkan untuk efisiensi, sementara ResNet152 mewakili arsitektur yang sangat dalam (*deep*) untuk akurasi tinggi, dan VGG16-BN mewakili arsitektur klasik yang lebih

sederhana. Untuk menjaga kompatibilitas arsitektur dan memastikan perbandingan yang adil, setiap model mempertahankan struktur *neck* (FPN dan PAN) dan *head* deteksi asli YOLOv5, serta seluruh *layer* dari *backbone* yang diintegrasikan tidak dibekukan (*unfrozen*) agar dapat dilatih sepenuhnya.

Karakteristik komputasi dari kelima arsitektur yang dibandingkan (termasuk *baseline* YOLOv5N) dirangkum dalam tabel 3.3.

Tabel 3. 3 Tabel perbandingan backbone CNN

No	Backbone	Layers	Parameters	GFLOPs
1	YOLOv5n (baseline)	**153**	9,127,223	24.1
2	EfficientNet-B1	469	9,544,898	**6.1**
3	ResNet-152	542	61,666,018	196.5
4	VGG16-BN	171	17,688,290	257.4
5	MobileNet-Large	363	**3,588,552**	6.7

Dari tabel 3.2, terlihat jelas bahwa arsitektur yang diuji memiliki karakteristik yang sangat bervariasi dibandingkan dengan *baseline* YOLOv5N, yang memiliki 153 *layers*, 9.1 juta *parameters*, dan 24.1 GFLOPs. Meskipun memiliki jumlah *layers* yang lebih banyak, EfficientNetB1 dan MobileNet-Large terbukti secara drastis lebih efisien daripada *baseline*, dengan nilai GFLOPs masing-masing hanya 6.1 dan 6.7. Bahkan, MobileNet-Large juga memiliki parameter paling sedikit, yakni 3.5 juta. Sebaliknya, ResNet-152 dan VGG16-BN menunjukkan kompleksitas komputasi yang jauh lebih tinggi, dengan nilai GFLOPs masing-masing 196.5 dan 257.4, di mana ResNet152 juga memiliki jumlah parameter terbesar yaitu 61.6 juta. Perbandingan metrik komputasi awal ini sangat penting untuk tahap analisis selanjutnya, yang bertujuan menentukan model mana yang memberikan keseimbangan (*trade-off*) terbaik antara akurasi prediksi dan efisiensi *deployment*.

3.4 Melatih Model

Proses pelatihan dilakukan untuk setiap model YOLOv5 dengan variasi *backbone* (EfficientNetB1, ResNet152, VGG16-BN, dan MobileNet-Large) menggunakan konfigurasi parameter yang identik. Penyeragaman ini sangat

penting untuk memastikan hasil perbandingan bersifat adil (*fair comparison*) dan objektif. Tahap pelatihan ini sendiri bertujuan untuk meminimalkan *loss function* yang merupakan kombinasi antara *objectness loss*, *classification loss*, dan *bounding box regression loss*. Parameter dan *hyperparameter* lengkap yang digunakan dalam proses pelatihan ditunjukkan pada Tabel 3.3.

Tabel 3. 4 Tabel Parameter pelatihan model

No.	Kategori Parameter	Nilai Parameter
1	Training Configuration	`epochs = 300, imgsz = 640, workers = 8`
2	Optimizer	`optimizer = SGD, momentum = 0.937, weight_decay = 0.0005, scaled_weight_decay = 0.0005`
3	Learning Rate	`lr0 = 0.01, lrf = 0.01`
4	Loss Function	`box = 0.05, cls = 0.5, cls_pw = 1.0, obj = 1.0, obj_pw = 1.0, iou_t = 0.2, anchor_t = 4.0, fl_gamma = 0.0`
5	Hardware Info	`device = CUDA:0, GPU = NVIDIA A100-SXM4-80GB, CUDA Memory = 81222MiB, torch = 2.8.0+cu126, Python = 3.12.12`

Parameter pelatihan diatur untuk berjalan selama 300 *epoch* dengan ukuran citra input 640x640 piksel, yang merupakan standar konfigurasi YOLOv5. *Optimizer* Stochastic Gradient Descent (SGD) dengan *momentum* 0.937 dipilih karena terbukti stabil untuk konvergensi jangka panjang pada dataset berukuran sedang. Nilai *learning rate* awal (lr0) dan *learning rate* final (lrf) diatur sama pada 0.01 agar pembelajaran berlangsung konstan tanpa penurunan drastis. Selain itu, teknik *warm-up* selama 3 *epoch* juga diterapkan untuk menstabilkan gradien pada awal proses pelatihan.

Dataset yang telah diaugmentasi dibagi menjadi tiga bagian: 89% untuk data latih (*train*), 8% untuk data validasi (*valid*), dan 3% untuk data uji (*test*). Setelah setiap *epoch* selesai, model dievaluasi menggunakan *set* validasi untuk memantau nilai *loss* dan mAP. Pelatihan dihentikan setelah 300 *epoch* tercapai, atau jika diamati tidak ada peningkatan mAP yang signifikan selama 20 *epoch* berturut-turut (melalui *early stopping* manual). Model terbaik dari setiap arsitektur disimpan berdasarkan pencapaian nilai mAP@0.5 tertinggi pada *set* validasi.

Berbagai teknik augmentasi data diterapkan untuk meningkatkan variasi data dan mengurangi risiko *overfitting* model. Augmentasi warna dilakukan dengan mengubah *hue*, *saturation*, dan *brightness* (HSV) pada citra input. Sementara itu, augmentasi geometrik meliputi translasi dan perubahan skala (*scale*) dengan probabilitas tertentu. Teknik *mosaic augmentation* juga diaktifkan dengan probabilitas 1.0, yang secara efektif menggabungkan beberapa citra latih berbeda menjadi satu *frame* untuk meningkatkan kemampuan model mengenali objek dalam berbagai konteks.

Seluruh proses pelatihan untuk semua model dieksekusi pada *hardware* yang sama, yaitu GPU NVIDIA A100-SXM4-80GB dengan dukungan CUDA. Penggunaan lingkungan pelatihan yang seragam ini krusial untuk memastikan bahwa perbandingan hasil tidak dipengaruhi oleh perbedaan spesifikasi perangkat keras. Dengan konfigurasi dan parameter pelatihan yang konsisten, hasil evaluasi diharapkan dapat merepresentasikan pengaruh murni dari arsitektur *backbone* terhadap performa model YOLOv5 secara objektif, baik dari sisi akurasi maupun efisiensi komputasi.

3.5 Analisis dan Evaluasi Hasil

Tahap evaluasi performa model dilakukan secara komprehensif menggunakan metrik akurasi standar, yang mencakup *Precision*, *Recall*, *mean Average Precision* pada ambang batas IoU 0.5 (mAP@0.5), serta mAP@0.5:0.95 untuk penilaian yang lebih ketat. IoU atau Intersection over Union adalah rasio tumpang tindih antara kotak prediksi dengan kotak sebenarnya, sehingga mAP@0.5 hanya menuntut tumpang tindih minimal 50 persen sedangkan mAP@0.5:0.95 merupakan rata rata performa pada sepuluh ambang IoU dari 0.5 sampai 0.95, sehingga jauh lebih ketat. Selain akurasi, efisiensi komputasi juga diukur secara ganda, yaitu menggunakan *Floating Point Operations* (FLOPs) untuk mengukur kompleksitas teoritis, dan *Frames Per Second* (FPS) untuk mengukur kecepatan inferensi di dunia nyata. Model dengan performa terbaik pada akhirnya akan ditentukan berdasarkan *efficiency score* tertinggi, yang dihitung dari rasio antara

nilai mAP@0.5 dan GFLOPs. Pendekatan ini memastikan bahwa model yang dipilih tidak hanya akurat tetapi juga efisien secara komputasi untuk *deployment*.

Untuk melaksanakan evaluasi ini, proses pengujian dijalankan menggunakan skrip validasi YOLOv5 yang telah dimodifikasi secara khusus. Modifikasi skrip ini bertujuan agar dapat mencatat metrik kompleksitas, dalam hal ini GFLOPs, serta waktu inferensi aktual per gambar secara otomatis. Data waktu inferensi per gambar tersebut kemudian digunakan untuk menghitung nilai FPS. Untuk menjamin perbandingan yang adil dan objektif, evaluasi performa ini dieksekusi menggunakan data uji yang sama untuk kelima varian arsitektur model. Selain itu, proses inferensi juga dilakukan pada perangkat keras yang identik dengan yang digunakan saat pelatihan, yaitu NVIDIA A100-SXM4-80GB, untuk memastikan konsistensi lingkungan pengujian.

BAB IV
HASIL PENELITIAN DAN PEMBAHASAN

Bab ini menyajikan dan menganalisis secara rinci seluruh temuan yang diperoleh dari rangkaian eksperimen yang telah dilaksanakan. Paparan akan diawali dengan Sub-bab 4.1, yang menyajikan hasil penelitian secara kuantitatif, menampilkan tabel perbandingan metrik performa (seperti *Precision*, *Recall*, mAP, GFLOPs, dan FPS) untuk kelima arsitektur model yang diuji. Selanjutnya, pada Sub-bab 4.2, akan dilakukan pembahasan dan analisis mendalam terhadap data tersebut. Fokus pembahasan adalah pada evaluasi komparatif, analisis *trade-off* antara akurasi dan efisiensi komputasi, serta penentuan nilai efisiensi untuk mengidentifikasi arsitektur *backbone* yang paling optimal sesuai dengan tujuan penelitian.

4.1 Hasil Penelitian

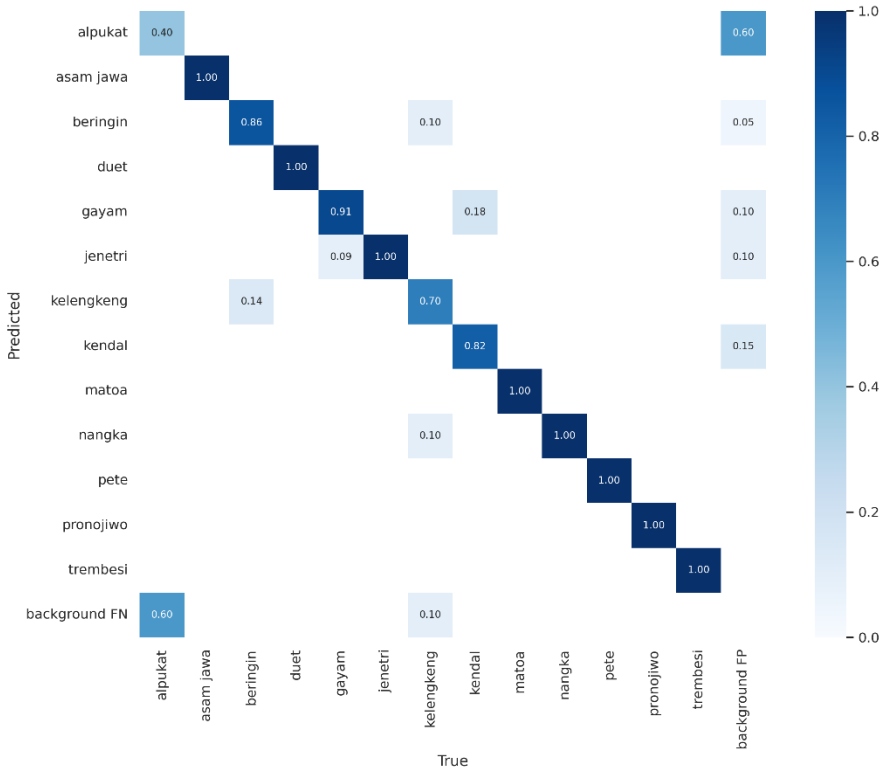
Bagian ini memaparkan hasil evaluasi performa dari lima varian model YOLOv5 dengan *backbone* yang berbeda, yaitu EfficientNetB1, ResNet152, VGG16-BN, MobileNet-Large, dan *baseline* YOLOv5N. Evaluasi dilakukan menggunakan dataset daun KHDTK dengan metrik Precision, Recall, mAP@0.5, mAP@0.5:0.95, serta GFLOPs dan FPS sebagai indikator efisiensi komputasi. Seluruh model dilatih menggunakan konfigurasi dan lingkungan komputasi yang sama untuk menjamin objektivitas hasil perbandingan yang diperoleh. Selain itu, hasil evaluasi ini juga digunakan untuk mengidentifikasi *trade-off*, yaitu hubungan timbal balik yang terjadi ketika peningkatan pada satu aspek justru menyebabkan penurunan pada aspek lain, khususnya antara kompleksitas arsitektur *backbone* dengan performa deteksi pada *dataset* daun lokal.

Tabel 4. 1 Hasil performa model

No	Backbone	Precision	Recall	mAP @0.5	mAP@ 0.5:0.95	GFLOPs	FPS
1	YOLOv5 N (Baseline)	0,956	0,985	0,980	0,871	24,1	80,2

2	EfficientNetB1	**0,904**	**0,898**	**0,911**	**0,733**	**6,1**	**47,3**
3	ResNet152	0,874	0,867	0,889	0,677	196,5	83,5
4	VGG16-BN	0,745	0,805	0,830	0,533	257,4	18,1
5	MobileNet-Large	0,839	0,879	0,884	0,650	6,7	21,4

Selain metrik global, analisis juga dilakukan terhadap *confusion matrix* untuk melihat tingkat kesalahan klasifikasi antar kelas daun. Visualisasi *confusion matrix* membantu dalam memahami pola kesalahan yang terjadi pada setiap kelas, seperti daun yang sering tertukar dengan kelas lain karena kemiripan bentuk atau tekstur. Gambar 4.1 menampilkan *confusion matrix* untuk model dengan *backbone* EfficientNetB1. Model ini menunjukkan keseimbangan terbaik antara akurasi dan efisiensi, sehingga dianggap paling optimal untuk diterapkan pada sistem identifikasi daun berbasis YOLOv5.



Gambar 4. 1 Diagram *confusion matrix* pada hasil YOLOv5 + EfficientNet

4.2 Pembahasan

4.2.1. Analisis Akurasi

Analisis dari segi akurasi menunjukkan bahwa model *baseline* YOLOv5N mencatatkan performa tertinggi, dengan *mean Average Precision* (mAP@0.5) mencapai 0,980. Di antara empat *backbone* kustom yang diuji, EfficientNetB1 menunjukkan performa tertinggi dengan mAP@0.5 sebesar 0,911. Performa ini kemudian diikuti oleh ResNet152 (0,889) dan MobileNet-Large (0,884), sementara VGG16-BN menunjukkan performa terendah dengan mAP@0.5 hanya 0,830.

Hasil ini mengonfirmasi bahwa prinsip *compound scaling* pada EfficientNetB1 menunjukkan efektivitas yang tinggi, menghasilkan akurasi yang baik dengan efisiensi komputasi yang impresif. Arsitektur ini terbukti hampir empat kali lebih efisien dibandingkan *baseline*, jika ditinjau dari metrik GFLOPs. Di sisi lain, MobileNet-Large juga menunjukkan hasil yang kompetitif, terutama mengingat arsitektur ini memiliki jumlah parameter paling sedikit. Sebaliknya, ResNet152 menunjukkan performa yang tidak seimbang; akurasi moderat yang dicapainya menuntut biaya komputasi GFLOPs yang sangat tinggi, mengindikasikan ketidaksepadanan antara hasil dan sumber daya yang dibutuhkan. Performa terburuk ditunjukkan oleh VGG16-BN, yang mengindikasikan bahwa arsitekturnya mungkin terlalu sederhana atau tidak optimal untuk tugas deteksi objek yang kompleks ini.

Selain performa global, analisis *confusion matrix* pada Gambar 4.1 mengungkap adanya kelemahan model dalam mengidentifikasi kelas alpukat secara spesifik. Pada model dengan *backbone* EfficientNetB1, hampir seluruh kelas menunjukkan warna dominan biru tua mendekati nilai 1.00 pada diagonal prediksi benar, kecuali kelas alpukat yang hanya mencapai nilai 0.40, artinya dari seluruh gambar yang diprediksi model sebagai alpukat, hanya 40 persen yang benar benar merupakan kelas alpukat. Pola serupa juga konsisten ditemukan pada *backbone* lain, yaitu MobileNet Large (0.20), ResNet152 (0.25), dan VGG16 BN (0.25), di mana kelas alpukat selalu menjadi kelas dengan nilai prediksi benar terendah di antara seluruh kelas yang diuji. Kondisi ini dapat disebabkan oleh minimnya data alpukat dengan detail fitur daun yang jelas melalui metode pemotretan individual,

mengingat seluruh data alpukat pada penelitian ini hanya diperoleh melalui metode in situ, sehingga model belum sepenuhnya memiliki pemahaman yang kuat terhadap karakteristik fitur daun alpukat

4.2.2. Analisis Efisiensi Komputasi

Jika ditinjau dari metrik efisiensi komputasi murni, yaitu GFLOPs, EfficientNetB1 muncul sebagai arsitektur yang paling efisien dengan nilai hanya 6,1 GFLOPs, diikuti sangat dekat oleh MobileNet-Large dengan 6,7 GFLOPs. Sebagai catatan, model *baseline* YOLOv5N yang memiliki akurasi tertinggi, ternyata membutuhkan komputasi yang jauh lebih besar, yaitu 24,1 GFLOPs, sementara arsitektur yang paling tidak efisien secara komputasi adalah ResNet152 dengan 196,5 GFLOPs dan VGG16-BN dengan 257,4 GFLOPs. Perbandingan ini dengan jelas menunjukkan bahwa arsitektur seperti EfficientNet dan MobileNet, yang secara fundamental dirancang untuk efisiensi, berhasil membuktikan keunggulannya dalam eksperimen ini, sebaliknya arsitektur yang lebih tua atau lebih dalam seperti ResNet dan VGG terbukti terlalu boros secara komputasi, sehingga manfaat akurasi yang ditawarkan, terutama oleh ResNet152, menjadi tidak sepadan jika dibandingkan dengan biaya komputasi yang sangat drastis.

Meskipun demikian, GFLOPs merupakan metrik teoritis yang murni mengukur kompleksitas komputasi arsitektur secara matematis, sehingga perlu divalidasi terhadap kecepatan inferensi yang terjadi secara nyata. Pengukuran Frames Per Second (FPS) pada perangkat keras NVIDIA A100 menunjukkan hasil yang tidak sepenuhnya sejalan dengan perbandingan GFLOPs tersebut. EfficientNetB1 tercatat hanya mencapai 47,33 FPS, justru lebih rendah dibandingkan *baseline* YOLOv5N yang mencapai 80,18 FPS, meskipun GFLOPs EfficientNetB1 jauh lebih kecil. Sebaliknya, MobileNet-Large mencatatkan FPS tertinggi di antara seluruh model yang diuji, yaitu 83,46 FPS, bahkan melampaui *baseline*. Pola serupa juga ditemukan pada ResNet152 dan VGG16-BN, di mana VGG16-BN justru mencatatkan FPS lebih tinggi (21,42) dibandingkan ResNet152 (18,05), meskipun nilai GFLOPs VGG16-BN lebih besar.

Untuk menguji konsistensi antara kedua metrik efisiensi tersebut secara kuantitatif, dilakukan uji Korelasi Rank Spearman antara GFLOPs dan FPS aktual pada kelima model yang diuji. Hasilnya menunjukkan koefisien korelasi (ρ) sebesar -0,600, yang tergolong hubungan negatif dengan kekuatan sedang menuju kuat, konsisten dengan ekspektasi bahwa GFLOPs yang lebih rendah cenderung berasosiasi dengan FPS yang lebih tinggi. Nilai signifikansi (p = 0,285) menunjukkan bahwa korelasi ini belum dapat dikatakan signifikan secara statistik, namun hal ini wajar mengingat jumlah sampel yang sangat terbatas (n = 5 arsitektur), dan tidak serta merta berarti hubungan antara kedua metrik tidak ada. Kekuatan korelasi yang tetap tergolong sedang hingga kuat ini justru menunjukkan bahwa GFLOPs tetap menjadi indikator yang relevan terhadap kecepatan inferensi secara umum, meskipun tidak sepenuhnya presisi, mengindikasikan adanya faktor lain di luar kompleksitas arsitektur murni, seperti tingkat optimasi implementasi, yang turut memengaruhi kecepatan eksekusi nyata suatu model.

4.2.3. Analisis Nilai Efisiensi

Untuk menemukan keseimbangan optimal atau *trade-off* antara akurasi dan efisiensi, dilakukan perhitungan nilai efisiensi. Metrik ini secara khusus mengukur seberapa besar akurasi yang mampu dihasilkan suatu arsitektur untuk setiap satuan biaya komputasi yang dikeluarkannya, sehingga menggambarkan efisiensi model secara menyeluruh, bukan sekadar akurasi atau efisiensi komputasi secara terpisah. Nilai efisiensi yang tinggi menandakan bahwa suatu model mampu mencapai akurasi yang baik dengan beban komputasi yang relatif rendah, sehingga arsitektur tersebut dinilai lebih ideal untuk diterapkan pada aplikasi yang menuntut kecepatan atau memiliki keterbatasan sumber daya, sedangkan nilai efisiensi yang rendah mengindikasikan bahwa model tersebut membutuhkan biaya komputasi yang besar untuk setiap satuan akurasi yang diperoleh, sehingga kurang optimal digunakan pada kondisi serupa. Metrik ini dihitung menggunakan formula pada persamaan 4.1, dengan hasil selengkapnya ditampilkan pada Tabel 4.2.

$$Nilai\ Efisiensi = \frac{mAP}{GFLOPs} \times 100 \tag{4.1}$$

Tabel 4. 2 Hasil Perhitungan Nilai Efisiensi

No	Kelas	mAP@0.5	GFLOPs	Nilai Efisiensi
1	YOLOv5N (Baseline)	0,980	24,1	4,07
2	**EfficientNetB1**	**0,911**	**6,1**	**14,93**
3	ResNet152	0,889	196,5	0,45
4	VGG16-BN	0,830	257,4	0,32
5	MobileNet-Large	0,884	6,7	13,19

Hasilnya menempatkan EfficientNetB1 sebagai arsitektur dengan performa paling seimbang, dengan skor 14,93. MobileNet-Large berada di posisi kedua dengan skor yang juga sangat baik, yaitu 13,19. Model *baseline* YOLOv5N, meskipun akurasinya tinggi, hanya mendapatkan skor 4,07, sementara ResNet152 dan VGG16-BN berada di posisi terendah dengan skor masing-masing 0,45 dan 0,32.

Analisis nilai efisiensi menunjukkan bahwa EfficientNetB1 menawarkan *trade-off* paling optimal. Nilai skor efisiensinya tercatat hampir 3,7 kali lebih tinggi dibandingkan *baseline* YOLOv5N, dengan perbandingan skor 14,93 terhadap 4,07. Meskipun demikian, perlu dicatat bahwa MobileNet-Large juga merupakan arsitektur alternatif yang sangat kompetitif. Arsitektur ini menawarkan efisiensi komputasi sebesar 6,7 GFLOPs, sebuah nilai yang hampir setara dengan EfficientNetB1. Namun, akurasi MobileNet-Large, dengan mAP@0.5 sebesar 0,884, tercatat sedikit berada di bawah EfficientNetB1, dan menunjukkan penurunan performa yang lebih signifikan pada metrik mAP@0.5:0.95 yang lebih ketat, di mana model ini hanya mencatatkan nilai 0,650.

Nilai Efisiensi pada penelitian ini dihitung berdasarkan GFLOPs, bukan FPS, karena GFLOPs bersifat intrinsik terhadap arsitektur dan tidak dipengaruhi oleh perangkat keras maupun tingkat optimasi implementasi, sehingga lebih representatif untuk membandingkan efisiensi rancangan arsitektur secara objektif dan konsisten. FPS EfficientNetB1 yang lebih rendah dibandingkan *baseline* tidak serta merta menggugurkan status efisiensinya, mengingat korelasi antara GFLOPs dan FPS masih tergolong sedang hingga kuat ($\rho = -0,600$), sehingga selisih tersebut

lebih mungkin disebabkan oleh belum diterapkannya optimasi inferensi lanjutan seperti TensorRT, dibandingkan kelemahan mendasar pada arsitekturnya. Dengan penghematan komputasi arsitektural hampir empat kali lipat dibandingkan baseline (24,1 menjadi 6,1 GFLOPs), akurasi 0,911 yang masih tergolong tinggi, serta latensi sebesar 21,13 milidetik yang jauh di bawah ambang batas yang dapat dipersepsikan pengguna aplikasi web, EfficientNetB1 ditetapkan sebagai arsitektur *backbone* paling optimal dalam penelitian ini, dengan selisih kecepatan inferensi aktual yang teridentifikasi menjadi arah optimasi bagi pengembangan lebih lanjut.

BAB V
PENUTUP

5.1 Kesimpulan

Berdasarkan analisis dan pembahasan hasil penelitian yang telah dilakukan, maka dapat ditarik kesimpulan yang menjawab tujuan penelitian sebagai berikut:

1. Penelitian ini telah berhasil melakukan rekonstruksi arsitektur YOLOv5 dengan mengimplementasikan empat variasi *backbone* CNN yang berbeda, yaitu EfficientNetB1, ResNet152, VGG16-BN, dan MobileNet-Large, dan berhasil melatih serta mengevaluasi seluruh model pada dataset daun KHDTK.
2. Analisis *trade-off* menunjukkan bahwa model *baseline* YOLOv5N mencapai akurasi mAP@0.5 tertinggi, dengan nilai 0,980, namun menuntut biaya komputasi yang relatif tinggi, yakni 24,1 GFLOPs. Sementara itu, arsitektur yang lebih berat seperti ResNet152 dengan 196,5 GFLOPs dan VGG16-BN dengan 257,4 GFLOPs terbukti sangat tidak efisien, baik secara GFLOPs maupun FPS aktual. Sebaliknya, arsitektur ringan seperti EfficientNetB1 yang hanya membutuhkan 6,1 GFLOPs dan MobileNet-Large dengan 6,7 GFLOPs menunjukkan efisiensi komputasi arsitektural yang jauh lebih unggul, yaitu sekitar empat kali lipat lebih efisien dibandingkan baseline, meskipun dengan sedikit penurunan akurasi menjadi 0,911 dan 0,884. Pengukuran FPS aktual turut menunjukkan bahwa EfficientNetB1 (47,33 FPS) lebih lambat dibandingkan baseline (80,18 FPS) dan MobileNet-Large (83,46 FPS), dengan uji Korelasi Rank Spearman antara GFLOPs dan FPS menghasilkan ρ = -0,600, mengindikasikan hubungan sedang hingga kuat namun tidak sepenuhnya presisi antara efisiensi arsitektural dan kecepatan inferensi nyata.
3. EfficientNetB1 ditentukan sebagai *backbone* dengan performa paling optimal di antara model yang diuji, berdasarkan keseimbangan atau *trade-off* terbaik antara akurasi dan efisiensi komputasi arsitektural, yang dibuktikan dengan pencapaian Nilai Efisiensi tertinggi, yakni 14,93, atau

3,7 kali lebih tinggi dibandingkan *baseline* yang hanya mencapai skor 4,07. Model ini berhasil mencapai akurasi mAP@0.5 yang tinggi, sebesar 0,911, dengan biaya komputasi GFLOPs terendah, yaitu 6,1 GFLOPs. Meskipun FPS aktualnya belum menjadi yang tertinggi, latensi inferensi sebesar 21,13 milidetik per gambar tetap berada jauh di bawah ambang batas yang dapat dirasakan pengguna, sehingga tidak mengurangi kelayakan model ini untuk diimplementasikan pada sistem informasi tanaman berbasis web.

4. Berdasarkan temuan tersebut, model YOLOv5 dengan *backbone* EfficientNetB1 merupakan model paling optimal yang paling sesuai dengan tujuan penelitian. Oleh karena itu, model ini yang dipilih untuk diimplementasikan ke dalam sistem informasi tanaman berbasis web guna mendukung kebutuhan identifikasi tanaman yang efisien dan akurat di lingkungan KHDTK Wanadipa.

5.2 Saran

Berdasarkan kesimpulan dan keterbatasan (batasan masalah) yang ada dalam penelitian ini, berikut adalah beberapa saran untuk pengembangan lebih lanjut:

1. Ekspansi dan Diversifikasi Dataset Penelitian selanjutnya disarankan untuk melakukan ekspansi dataset secara masif, mengingat penelitian ini terbatas pada 13 spesies dari satu lokasi. Peningkatan robustisitas model dapat dicapai dengan menambah jumlah kelas spesies (mendekati 114 spesies di KHDTK) dan melakukan diversifikasi pengambilan gambar dalam berbagai kondisi pencahayaan, cuaca, musim, serta kondisi kesehatan daun.
2. Implementasi perangkat bergerak untuk Inferensi *On-Device* Disarankan untuk berfokus pada *deployment* model ke dalam aplikasi *mobile* (Android/iOS) untuk penggunaan *on-device* secara *offline*, yang lebih optimal untuk penggunaan di lapangan. Proses ini dapat melibatkan teknik optimalisasi seperti kuantisasi model (misalnya, konversi ke TFLite) agar dapat memberikan solusi identifikasi yang portabel dan instan bagi pengunjung di seluruh area KHDTK.

3. Berdasarkan temuan bahwa FPS pada EfficientNetB1 belum sepenuhnya merepresentasikan keunggulan teoritisnya pada metrik GFLOPs, penelitian selanjutnya disarankan untuk menerapkan teknik optimasi inferensi lanjutan, seperti konversi model ke *runtime* khusus (TensorRT atau ONNX Runtime), *kernel fusion*, maupun kuantisasi presisi (FP16 atau INT8). Penerapan optimasi ini berpotensi merealisasikan kecepatan inferensi yang lebih mendekati potensi efisiensi arsitektural EfficientNetB1, sekaligus memberikan perbandingan yang lebih komprehensif antara kompleksitas teoritis dan performa praktis pada instalasi perangkat keras yang sesungguhnya

DAFTAR PUSTAKA

[1] S. E. Sumanto and M. Takandjandji, "Identifikasi Pemanfaatan Hasil Hutan oleh Masyarakat: Upaya Konservasi Sumber Daya Genetik dan Sosial Budaya," *Buletin Plasma Nutfah*, vol. 20, no. 1, p. 27, Oct. 2016, doi: 10.21082/blpn.v20n1.2014.p27-40.

[2] J. Lu, L. Tan, and H. Jiang, "Review on Convolutional Neural Network (CNN) Applied to Plant Leaf Disease Classification," *Agriculture*, vol. 11, no. 8, p. 707, Jul. 2021, doi: 10.3390/agriculture11080707.

[3] O. E. Olorunshola, M. E. Irhebhude, and A. E. Evwiekpaefe, "A Comparative Study of YOLOv5 and YOLOv7 Object Detection Algorithms," *Journal of Computing and Social Informatics*, vol. 2, no. 1, pp. 1–12, Feb. 2023, doi: 10.33736/jcsi.5070.2023.

[4] A. Nur, A. N. Setio, J. Firman, R. Rahmat Shofan, and A. Ansori, "ALGORITMA DEEP LEARNING UNTUK PENGENALAN GAMBAR JENIS DAUN Deep Learning Algorithm for Leaf Type Image Recognition," Sep. 2024. [Online]. Available: http://journal.umpalangkaraya.ac.id/index.php/anterior

[5] S. Salsabila and A. Suharso, "Comparison of Deep Learning Architectures in Identifying Types of Medicinal Plant Leaf Images," 2024. [Online]. Available: http://jurnal.polibatam.ac.id/index.php/JAIC

[6] S. W. Athapaththu and U. A. Piumi Ishanka, "Plant Leaf Recognition Using Texture, Colour, and Vein Density Features," in *2023 3rd International Conference on Advanced Research in Computing (ICARC)*, IEEE, Feb. 2023, pp. 102–107. doi: 10.1109/ICARC57651.2023.10145733.

[7] N. K. Trivedi, H. Maheshwari, R. G. Tiwari, V. Gautam, and A. K. Agarwal, "Hybrid Deep Learning for Thai Cannabis Plant Classification: YOLO+CNN Approach," in *3rd International Conference on Innovative Mechanisms for Industry Applications, ICIMIA 2023 - Proceedings*, Institute of Electrical and Electronics Engineers Inc., 2023, pp. 695–700. doi: 10.1109/ICIMIA60377.2023.10426583.

[8] J. Singh and R. Kumar, “Object Recognition in Images Using Hybrid Deep Learning Model,” 2023.

[9] B. J. Souza, S. F. Stefenon, G. Singh, and R. Z. Freire, “Hybrid-YOLO for classification of insulators defects in transmission lines based on UAV,” *International Journal of Electrical Power & Energy Systems*, vol. 148, p. 108982, Jun. 2023, doi: 10.1016/j.ijepes.2023.108982.

[10] N. Mishra, I. Jahan, Md. R. Nadeem, and V. Sharma, “A Comparative Study of ResNet50, EfficientNetB7, InceptionV3, VGG16 models in Crop and Weed classification,” in *2023 4th International Conference on Intelligent Engineering and Management (ICIEM)*, IEEE, May 2023, pp. 1–5. doi: 10.1109/ICIEM59379.2023.10166032.

[11] P. Wang, S. Li, W. Wang, K. Tang, and F. Chen, “Metal Defect Detection Models Fused EfficientNet and Involution,” *J. Sens.*, vol. 2024, no. 1, Jan. 2024, doi: 10.1155/js/6074853.

[12] W. Shafik, A. Tufail, C. De Silva Liyanage, and R. A. A. H. M. Apong, “Using transfer learning-based plant disease classification and detection for sustainable agriculture,” *BMC Plant Biol.*, vol. 24, no. 1, p. 136, Feb. 2024, doi: 10.1186/s12870-024-04825-y.

[13] V. Balafas, E. Karantoumanis, M. Louta, and N. Ploskas, “Machine Learning and Deep Learning for Plant Disease Classification and Detection,” *IEEE Access*, vol. 11, pp. 114352–114377, 2023, doi: 10.1109/ACCESS.2023.3324722.

[14] J. Andrew, J. Eunice, D. E. Popescu, M. K. Chowdary, and J. Hemanth, “Deep Learning-Based Leaf Disease Detection in Crops Using Images for Agricultural Applications,” *Agronomy*, vol. 12, no. 10, p. 2395, Oct. 2022, doi: 10.3390/agronomy12102395.

[15] R. Khanam and M. Hussain, “What is YOLOv5: A deep look into the internal features of the popular object detector,” Jul. 2024.

[16] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” Dec. 2015.

[17] A. Zaeemzadeh, N. Rahnavard, and M. Shah, “Norm-Preservation: Why Residual Networks Can Become Extremely Deep?,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 11, pp. 3980–3990, Nov. 2021, doi: 10.1109/TPAMI.2020.2990339.

[18] R. P. Monti, S. Tootoonian, and R. Cao, “Avoiding Degradation in Deep Feed-Forward Networks by Phasing Out Skip-Connections,” 2018, pp. 447–456. doi: 10.1007/978-3-030-01424-7_44.

[19] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” Sep. 2020.

[20] J. Padhi, L. Korada, A. Dash, P. K. Sethy, S. K. Behera, and A. Nanthaamornphong, “Paddy Leaf Disease Classification Using EfficientNet B4 With Compound Scaling and Swish Activation: A Deep Learning Approach,” *IEEE Access*, vol. 12, pp. 126426–126437, 2024, doi: 10.1109/ACCESS.2024.3451557.

[21] Y. Zhou, H. Chang, Y. Lu, X. Lu, and R. Zhou, “Improving the Performance of VGG Through Different Granularity Feature Combinations,” *IEEE Access*, vol. 9, pp. 26208–26220, 2021, doi: 10.1109/ACCESS.2020.3031908.

[22] V. Thakkar, S. Tewary, and C. Chakraborty, “Batch Normalization in Convolutional Neural Networks — A comparative study with CIFAR-10 data,” in *2018 Fifth International Conference on Emerging Applications of Information Technology (EAIT)*, IEEE, Jan. 2018, pp. 1–5. doi: 10.1109/EAIT.2018.8470438.

[23] N. Zakaria and Y. M. Mohmad Hassim, “Improved Image Classification Task Using Enhanced Visual Geometry Group of Convolution Neural Networks,” *JOIV : International Journal on Informatics Visualization*, vol. 7, no. 4, p. 2498, Dec. 2023, doi: 10.30630/joiv.7.4.1752.

[24] S.-F. Hsiao and B.-C. Tsai, “Efficient Computation of Depthwise Separable Convolution in MoblieNet Deep Neural Network Models,” in *2021 IEEE International Conference on Consumer Electronics-Taiwan (ICCE-TW)*, IEEE, Sep. 2021, pp. 1–2. doi: 10.1109/ICCE-TW52618.2021.9602973.

[25] T. Jaya, M. Gopika, R. Hemkumar, and Nath. Srigitha S, “Optimized MobileNet Architecture for Accurate and Efficient Wildlife Classification in IoT Applications,” in *2025 International Conference on Visual Analytics and Data Visualization (ICVADV)*, IEEE, Mar. 2025, pp. 435–439. doi: 10.1109/ICVADV63329.2025.10960847.

[26] T. Kumar, R. Brennan, A. Mileo, and M. Bendechache, “Image Data Augmentation Approaches: A Comprehensive Survey and Future Directions,” *IEEE Access*, vol. 12, pp. 187536–187571, 2024, doi: 10.1109/ACCESS.2024.3470122.

[27] C. Khandelwal, “Data Augmentation Techniques for ML Models: Enhancing Model Performance Through Data Variability,” *International Journal of Multidisciplinary Research and Growth Evaluation*, pp. 279–283, 2021, doi: 10.54660/.IJMRGE.2021.2.1-279-283.

[28] R. Padilla, S. L. Netto, and E. A. B. da Silva, “A Survey on Performance Metrics for Object-Detection Algorithms,” in *2020 International Conference on Systems, Signals and Image Processing (IWSSIP)*, IEEE, Jul. 2020, pp. 237–242. doi: 10.1109/IWSSIP48289.2020.9145130.

[29] T.-Y. Lin *et al.*, “Microsoft COCO: Common Objects in Context,” in *Computer Vision – ECCV*, 2014, pp. 740–755. doi: 10.1007/978-3-319-10602-1_48.

[30] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, Jun. 2016, pp. 779–788. doi: 10.1109/CVPR.2016.91.

[31] M. Dehghani, A. Arnab, L. Beyer, A. Vaswani, and Y. Tay, “The Efficiency Misnomer,” *International Conference on Learning Representations (ICLR)*, Mar. 2022.

BIODATA MAHASISWA



Nama Mahasiswa	:	Zeka Emo
NIM	:	21120122130075
Konsentrasi	:	Kecerdasan Buatan
Tempat/Tgl. Lahir	:	Semarang/30 Maret 2004
Alamat Sekarang	:	Srondol Asri Blok M No. 4 Banyumanik, Semarang
No.Telepon/HP	:	+62-85171614749
Alamat e-mail	:	Zeka.emo30@gmail.com
Nama Orang Tua	:	Pranavita
Alamat Orang Tua	:	S. Parman No. 50, Kabupaten Semarang
No Telp	:	+62-85869829666
IP Kumulatif	:	3,88
Tanggal Lulus	:	.....
Masa Studi	:	.....

Semarang, 14 Agustus 2026

ZEKA EMO

LAMPIRAN